

HỌC TĂNG CƯỜNG NHẠY CẢM RỦI RO CHO GIAO DỊCH ĐỊNH LƯỢNG (Risk-Sensitive Reinforcement Learning for Quantitative Trading)

NGUYỄN NGỌC LÂN¹, LÊ HUỲNH TẤN ĐẠT¹, BÙI THANH HÙNG¹

¹Khoa Công nghệ thông tin, Đại học Công nghiệp Thành phố Hồ Chí Minh

22635801.lan@student.iuh.edu.vn, 23634031.dat@student.iuh.edu.vn,

buithanhhung@iuh.edu.vn

Corresponding email: buithanhhung@iuh.edu.vn

Tóm tắt: Giao dịch định lượng là bài toán ra quyết định theo chuỗi thời gian, trong đó mỗi hành động mua, bán hoặc nắm giữ tài sản đều ảnh hưởng đến trạng thái danh mục ở các thời điểm tiếp theo. Vì vậy, việc đánh giá một chiến lược giao dịch không nên chỉ dựa trên lợi nhuận tuyệt đối mà cần xem xét thêm các yếu tố rủi ro như biến động lợi nhuận, mức sụt giảm tối đa và rủi ro trong các giai đoạn thị trường bất lợi. Đề tài này xây dựng một hệ thống thử nghiệm giao dịch định lượng sử dụng học tăng cường sâu theo hướng nhạy cảm rủi ro. Hệ thống không dự báo trực tiếp giá cổ phiếu, mà học chính sách giao dịch dựa trên trạng thái thị trường và trạng thái danh mục. Các mô hình được triển khai và so sánh gồm PPO, CVaR-PPO, Sortino-PPO và chiến lược Buy & Hold làm chuẩn đối chiếu. Quy trình thực hiện bao gồm thu thập dữ liệu OHLCV, xây dựng các chỉ báo kỹ thuật, chuẩn hóa đặc trưng, tạo trạng thái đầu vào, sinh hành động giao dịch và tiến hành backtest. Kết quả thực nghiệm cho thấy Buy & Hold đạt lợi nhuận tuyệt đối cao nhất trong giai đoạn kiểm thử 2023–2024, phù hợp với bối cảnh thị trường tăng mạnh. Tuy nhiên, các mô hình học tăng cường có ý nghĩa trong việc kiểm soát rủi ro: CVaR-PPO đạt Total Return 21,80%, Sharpe Ratio 1,303 trên SPY, trong khi PPO có Max Drawdown thấp nhất. Hệ thống được triển khai dưới dạng web demo Django hỗ trợ tạo tín hiệu giao dịch, chạy backtest và so sánh các mô hình theo thời gian thực.

Từ khoá: Giao dịch định lượng, học tăng cường sâu, PPO, CVaR-PPO, Sortino-PPO, quản trị rủi ro, backtest, chuỗi thời gian tài chính

1. GIỚI THIỆU

Đề tài Risk-Sensitive Reinforcement Learning for Trading tập trung xây dựng một hệ thống thử nghiệm giao dịch định lượng sử dụng học tăng cường sâu. Hệ thống không dự báo trực tiếp giá cổ phiếu, mà học chính sách giao dịch dựa trên trạng thái thị trường và trạng thái danh mục. Từ trạng thái đầu vào, mô hình sinh ra hành động liên tục, sau đó được diễn giải thành tín hiệu BUY, SELL hoặc HOLD trong quá trình demo và backtest.

Bài toán được mô hình hóa theo hướng ra quyết định tuần tự. Ở mỗi thời điểm giao dịch, hệ thống quan sát dữ liệu thị trường, các chỉ báo kỹ thuật và thông tin danh mục hiện tại. Dựa trên trạng thái này, policy quyết định mức độ mua, bán hoặc giữ tài sản. Quyết định tại một thời điểm ảnh hưởng đến trạng thái danh mục ở các thời điểm sau, do đó bài toán không chỉ phụ thuộc vào biến động giá mà còn phụ thuộc vào cách quản lý vị thế và rủi ro.

Trong phạm vi đề tài, các mô hình được so sánh gồm: PPO (Proximal Policy Optimization) làm mô hình cơ sở trung lập rủi ro, CVaR-PPO bổ sung góc nhìn về rủi ro đuôi, Sortino-PPO tập trung vào biến động bất lợi, và Buy & Hold làm benchmark thụ động.

Hệ thống được triển khai dưới dạng web demo bằng Django, hỗ trợ tạo tín hiệu giao dịch theo thời gian thực, chạy backtest và so sánh kết quả giữa các mô hình thông qua các chỉ số Total Return, Sharpe Ratio, Sortino Ratio, Max Drawdown, Volatility, Win Rate và Number of Trades.

Ý nghĩa chính của bài toán nằm ở việc đánh giá chiến lược giao dịch không chỉ dựa trên lợi nhuận cuối kỳ mà còn dựa trên mức độ rủi ro đi kèm. Các đóng góp chính của nghiên cứu bao gồm:

- Xây dựng hệ thống giao dịch định lượng dựa trên học tăng cường sâu với ba mô hình nhạy cảm rủi ro và một benchmark thụ động.
- Thiết lập quy trình xử lý dữ liệu, tạo vector trạng thái 19 chiều kết hợp đặc trưng thị trường và biến danh mục.
- So sánh toàn diện PPO, CVaR-PPO, Sortino-PPO và Buy & Hold trên nhiều tài sản (SPY, QQQ, GLD) theo các chỉ số lợi nhuận và rủi ro.
- Triển khai hệ thống web demo Django hỗ trợ tạo tín hiệu thời gian thực và so sánh chiến lược trực quan.

Các phần còn lại của bài báo được tổ chức như sau: Phần 2 trình bày các nghiên cứu liên quan. Phần 3 mô tả mô hình và phương pháp đề xuất. Phần 4 trình bày thực nghiệm và kết quả đánh giá. Phần 5 là kết luận và hướng phát triển.

2. CÁC NGHIÊN CỨU CÓ LIÊN QUAN

Giao dịch định lượng bằng học tăng cường đã được nghiên cứu từ nhiều góc độ khác nhau. Moody và Saffell (2001) [1] đề xuất thuật toán Recurrent Reinforcement Learning (RRL) để học trực tiếp chiến lược giao dịch, tối ưu differential Sharpe ratio mà không cần xây dựng mô hình dự báo giá trước. Phương pháp này được áp dụng thành công cho giao dịch nội ngày cặp tiền ngoại hối.

Jiang, Xu và Liang (2017) [2] đề xuất framework Financial Reinforcement Learning (FRL) cho quản lý danh mục đầu tư đa tài sản, sử dụng đặc trưng OHLCV và chỉ báo kỹ thuật để huấn luyện policy network phân bổ vốn. Kết quả vượt trội so với các benchmark truyền thống như Uniform Buy & Hold và Mean-Variance Portfolio.

Schulman và cộng sự (2017) [3] đề xuất Proximal Policy Optimization (PPO) với Clipped Surrogate Objective nhằm cải thiện độ ổn định của quá trình cập nhật policy, phù hợp với không gian hành động liên tục và ổn định hơn so với các thuật toán policy gradient truyền thống.

Rockafellar và Uryasev (1999) [4] trình bày phương pháp tối ưu Conditional Value-at-Risk (CVaR), tập trung vào phần đuôi xấu của phân phối tổn thất. CVaR không chỉ quan tâm đến ngưỡng rủi ro như VaR, mà còn xem xét mức tổn thất kỳ vọng trong các trường hợp xấu nhất.

Sortino và Price (1994) [5] đề xuất Sortino Ratio, chỉ số đánh giá hiệu quả đầu tư dựa trên downside risk, chỉ tập trung vào biến động bất lợi thay vì toàn bộ biến động lợi nhuận. Chỉ số này phù hợp hơn trong bài toán giao dịch định lượng so với Sharpe Ratio truyền thống.

Các nghiên cứu gần đây (Théate & Ernst, 2021 [6]; Liu et al., 2020 [7]) đã đề xuất các framework học tăng cường cho giao dịch chứng khoán thuật toán, bao gồm FinRL — một thư


viện mã nguồn mở tích hợp nhiều thuật toán RL cho giao dịch tài chính tự động. Những công trình này đặt nền tảng để đề tài này phát triển theo hướng nhảy cảm rủi ro.


3. MÔ HÌNH VÀ CÁC ĐẶC TRƯNG

3.1. Mô hình tổng quát

Hệ thống đề xuất gồm hai giai đoạn chính (Hình 1):

- Giai đoạn xử lý dữ liệu và huấn luyện mô hình học tăng cường.
- Giai đoạn suy luận và backtest, triển khai qua web demo Django.






Hình 1. Quy trình tổng thể hệ thống RL cho giao dịch định lượng

Quy trình bao gồm các bước: thu thập dữ liệu OHLCV từ Yahoo Finance, tiền xử lý và tính chỉ báo kỹ thuật, xây dựng vector trạng thái 19 chiều, huấn luyện các agent theo thuật toán PPO/CVaR-PPO/Sortino-PPO, và đánh giá kết quả trên tập test thông qua backtest.

3.2. Xử lý dữ liệu và trích xuất đặc trưng

3.2.1. Thu thập và tiền xử lý dữ liệu

Hệ thống thu thập dữ liệu lịch sử từ Yahoo Finance thông qua thư viện yfinance, chuẩn hóa theo định dạng OHLCV (date, open, high, low, close, volume). Dữ liệu bao gồm ba tài sản: SPY (ETF S&P 500), QQQ (ETF Nasdaq-100) và GLD (ETF vàng), giai đoạn 2018–2024.



Hình 2. Quy trình thu thập và tiền xử lý dữ liệu thị trường

Quy trình tiền xử lý gồm: sắp xếp theo thứ tự thời gian, loại bỏ bản ghi trùng lặp và giá trị không hợp lệ, tính toán các chỉ báo kỹ thuật, loại bỏ NaN sau giai đoạn khởi động chỉ báo, và chuẩn hóa đặc trưng bằng Z-score theo tham số tập train.

3.2.2. Trích xuất đặc trưng và vector trạng thái

Vector trạng thái 19 chiều được xây dựng từ 16 đặc trưng thị trường và 3 biến danh mục:

Nhóm đặc trưng thị trường (16 chiều):

- Price & Return: close, returns, log_returns
- Trend & Momentum: SMA10, SMA20, SMA50, RSI, MACD, MACDsignal, MACDdiff
- Volatility: Bollinger Bands (bbhigh, bbmid, bblow), ATR
- Volume: volume, volumesma

Nhóm biến danh mục (3 chiều):

- cash_ratio: tỷ lệ tiền mặt so với vốn ban đầu
- shares_value_ratio: tỷ lệ giá trị cổ phiếu so với vốn ban đầu
- portfolio_value_ratio: tỷ lệ tổng giá trị danh mục so với vốn ban đầu

Vector trạng thái cuối: $st = [\text{close}, \text{volume}, \text{sma10}, \text{sma20}, \text{sma50}, \text{rsi}, \text{macd}, \text{macdsignal}, \text{macddiff}, \text{bbhigh}, \text{bblow}, \text{bbmid}, \text{atr}, \text{returns}, \text{logreturns}, \text{volumesma}, \text{cash_ratio}, \text{shares_value_ratio}, \text{portfolio_value_ratio}]$

3.3. Môi trường giao dịch và mô hình hóa bài toán

3.3.1. Không gian hành động

Không gian hành động được thiết kế liên tục trong khoảng $[-1, 1]$. Giá trị hành động thể hiện mức độ can thiệp của agent vào danh mục:

- $at > 0,01$: tín hiệu BUY — sử dụng tỷ lệ tiền mặt tương ứng để mua cổ phiếu.
- $at < -0,01$: tín hiệu SELL — bán tỷ lệ cổ phiếu tương ứng.
- $-0,01 \leq at \leq 0,01$: tín hiệu HOLD — giữ nguyên danh mục.

3.3.2. Chi phí giao dịch và trượt giá

Để mô phỏng gần với điều kiện thực tế, môi trường áp dụng chi phí giao dịch 0,1% mỗi lần mua/bán và mức trượt giá 0,05%. Khi mua, giá khớp lệnh được điều chỉnh cao hơn giá thị trường; khi bán, giá khớp lệnh được điều chỉnh thấp hơn. Cơ chế này hạn chế hiện tượng giao dịch quá mức.

3.3.3. Hàm phần thưởng

Hàm phần thưởng cơ sở dựa trên tỷ suất thay đổi giá trị danh mục:

$$R_t = \frac{V_t - V_{t-1}}{V_{t-1}} \quad (1)$$

Trong đó V_t là giá trị danh mục tại thời điểm t và V_{t-1} là giá trị danh mục ở thời điểm trước. Cách thiết kế này giúp agent học tối đa hóa mức tăng trưởng danh mục theo thời gian.

3.4. Các mô hình học tăng cường

Tất cả ba mô hình sử dụng chung kiến trúc Actor-Critic với hidden dimension 256. Actor nhận vector trạng thái và sinh hành động trong khoảng $[-1, 1]$; Critic ước lượng giá trị trạng thái để hỗ trợ cập nhật chính sách.

PPO (Proximal Policy Optimization)

PPO làm mô hình cơ sở trung lập rủi ro, tối ưu hóa Clipped Surrogate Objective:

$$L^{\text{CLIP}}(\theta) = E_t[\min(r_t(\theta) \cdot \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \cdot \hat{A}_t)] \quad (2)$$

Trong đó $r_t(\theta)$ là tỷ lệ xác suất giữa chính sách mới và chính sách cũ, $\hat{A}_t$ là ước lượng advantage, $\epsilon = 0,2$ là ngưỡng clip.

CVaR-PPO (Conditional Value-at-Risk PPO)

CVaR-PPO bổ sung thành phần phạt rủi ro đuôi vào hàm loss:

$$CVaR_\alpha = \frac{1}{|S_\alpha|} \cdot \sum_{r \in S_\alpha} r \quad (3)$$

Trong đó S_α là tập các return bất lợi thuộc nhóm $\alpha = 0,15$ (15% tệ nhất) trong batch huấn luyện. Hàm loss tổng hợp:

$$L_{CVaR-PPO}(\theta) = L^{CLIP}(\theta) - \lambda_{CVaR} \cdot CVaR_\alpha \quad (4)$$

Với $\lambda_{CVaR} = 0,15$, giảm dần đến 0,08 trong quá trình huấn luyện.

Sortino-PPO (Downside Risk PPO)

Sortino-PPO điều chỉnh reward dựa trên downside deviation:

$$\sigma_d = \sqrt{\frac{1}{T} \cdot \sum_t \min(r_t, 0)^2} \quad (5)$$

Reward được điều chỉnh:

$$R'_t = R_t - \lambda_{Sortino} \cdot \sigma_d \quad (6)$$

Với $\lambda_{Sortino} = 0,2$, giúp agent tập trung giảm thiểu biến động bất lợi.

Bảng 1. Tóm tắt vai trò của từng mô hình trong hệ thống đề xuất

Mô hình	Vai trò	Yếu tố tối ưu	Đặc điểm
Buy & Hold	Benchmark	Lợi nhuận thụ động	Mua đầu kỳ, giữ đến cuối kỳ
PPO	Mô hình cơ sở	Lợi nhuận kỳ vọng	Trung lập rủi ro, baseline
CVaR-PPO	Nhạy cảm rủi ro đuôi	Hạn chế thua lỗ lớn nhất	Penalty dựa trên CVaR của return batch
Sortino-PPO	Nhạy cảm downside risk	Giảm biến động bất lợi	Điều chỉnh reward bằng σ_d

3.5. Quy trình huấn luyện và suy luận

Huấn luyện thực hiện theo thứ tự thời gian, không xáo trộn dữ liệu. Mỗi episode khởi tạo lại môi trường với vốn ban đầu 10.000 USD. Agent đi qua từng ngày giao dịch trong tập train, nhận reward và cập nhật chính sách mỗi 256 bước. Tổng số episodes: 300.

Ở giai đoạn suy luận, hệ thống tải trọng số đã huấn luyện và tham số chuẩn hóa từ tập train (norm_params.json). Dữ liệu đầu vào mới được chuẩn hóa theo cùng tham số, sau đó agent sinh hành động giao dịch được chuyển thành tín hiệu BUY/SELL/HOLD.

Bảng 2. Sự khác biệt trong quá trình huấn luyện giữa các mô hình

Mô hình	Cách huấn luyện	Mục đích
PPO	Cập nhật policy dựa trên reward là tỷ suất thay đổi giá trị danh mục	Mô hình cơ sở trung lập rủi ro
CVaR-PPO	Bổ sung penalty từ nhóm return xấu nhất trong batch (15%)	Hạn chế rủi ro đuôi và tình huống thua lỗ lớn
Sortino-PPO	Điều chỉnh reward bằng cách phạt downside deviation	Giảm downside risk, danh mục ổn định hơn

4. THỰC NGHIỆM

4.1. Dữ liệu

Dữ liệu thực nghiệm được thu thập từ Yahoo Finance thông qua thư viện yfinance, giai đoạn 01/01/2018 – 31/12/2024, tần suất ngày. Sau khi xử lý, mỗi tài sản có 1.711 dòng dữ liệu hợp lệ.

Dữ liệu được chia theo thứ tự thời gian để phù hợp với đặc điểm chuỗi thời gian và tránh rò rỉ thông tin từ tương lai:

Bảng 3. Phân chia tập dữ liệu và vai trò từng giai đoạn

Tập dữ liệu	Giai đoạn	Vai trò	Đặc điểm thị trường
Train	2018–2021	Huấn luyện	Xu hướng tăng và giai đoạn COVID-19
Validation	2022	Kiểm tra trong huấn luyện	Giai đoạn thị trường giảm mạnh
Test	2023–2024	Đánh giá kết quả cuối	Giai đoạn phục hồi và tăng trưởng

Bảng 4. Vai trò và ý nghĩa các tài sản trong thực nghiệm

Tài sản	Ý nghĩa	Vai trò trong thực nghiệm
SPY	ETF mô phỏng S&P 500	Tài sản chính để huấn luyện và kiểm thử
QQQ	ETF mô phỏng Nasdaq-100	Đánh giá khả năng tổng quát hóa trên nhóm tăng trưởng
GLD	ETF đại diện cho vàng	Đánh giá khả năng tổng quát hóa trên tài sản khác nhóm

4.2. Xử lý dữ liệu

Bảng 5. Các bước xử lý dữ liệu và mục đích

Bước xử lý	Mục đích
Sắp xếp dữ liệu theo thời gian	Đảm bảo đúng thứ tự chuỗi thời gian
Loại bỏ dòng trùng, giá trị thiếu hoặc không hợp lệ	Làm sạch dữ liệu đầu vào
Tính toán chỉ báo kỹ thuật (SMA, RSI, MACD, BB, ATR...)	Tạo đặc trưng cho vector trạng thái thị trường
Loại bỏ NaN sau indicator warm-up	Đảm bảo mỗi mẫu có đầy đủ đặc trưng
Chuẩn hóa Z-score bằng tham số từ tập train	Giảm khác biệt thang đo và hạn chế data leakage

4.3. Công nghệ sử dụng

- Ngôn ngữ lập trình: Python.
- Thu thập dữ liệu: yfinance.
- Xử lý dữ liệu: Pandas, NumPy.
- Tính toán chỉ báo kỹ thuật: ta (Technical Analysis Library).
- Huấn luyện mô hình RL: PyTorch, Gymnasium.
- Trực quan hóa và web demo: Matplotlib, Plotly, Django.

4.4. Cách đánh giá

Giá trị danh mục tại thời điểm t ký hiệu là V_t ; tỷ suất lợi nhuận hàng ngày được tính theo công thức (1). Từ chuỗi giá trị danh mục và chuỗi lợi nhuận, hệ thống tính các chỉ số đánh giá sau:

Bảng 6. Các chỉ số đo lường hiệu quả chiến lược giao dịch

Độ đo	Công thức	Ý nghĩa
Total Return	$\frac{V_T - V_0}{V_0}$	Tỷ suất sinh lời tổng trong toàn giai đoạn
Annualized Return	$(1 + R_{total})^{\frac{252}{N}} - 1$	Lợi nhuận quy đổi theo năm, N là số ngày
Volatility	$\sigma(r_t) \cdot \sqrt{252}$	Biến động lợi nhuận quy năm
Sharpe Ratio	$\frac{E[r_t]}{\sigma(r_t)} \cdot \sqrt{252}$	Lợi nhuận trên mỗi đơn vị rủi ro tổng thể

Sortino Ratio	$\frac{E[r_t]}{\sigma_d} \cdot \sqrt{252}$	Lợi nhuận trên mỗi đơn vị rủi ro bất lợi
Max Drawdown	$\min_t \frac{V_t - \max_{s \leq t} V_s}{\max_{s \leq t} V_s}$	Mức sụt giảm lớn nhất từ đỉnh xuống đáy
VaR-95	Phân vị 5% chuỗi r_t	Ngưỡng lỗ trong 5% trường hợp xấu nhất
CVaR-95	$E[r_t r_t \leq \text{VaR-95}]$	Mức lỗ trung bình trong nhóm tình huống xấu nhất
Win Rate	Số ngày $r_t > 0$ / Tổng số ngày	Tỷ lệ ngày giao dịch có lợi nhuận dương

4.5. Kết quả đạt được

4.5.1. Thiết lập tham số thực nghiệm

Bảng 7. Tham số huấn luyện và đánh giá mô hình

Nhóm	Tham số	Giá trị
Dữ liệu	Tài sản	SPY, QQQ, GLD
Dữ liệu	Giai đoạn / Train / Val / Test	2018–2024 / 2018–2021 / 2022 / 2023–2024
Môi trường	Vốn ban đầu	10.000 USD
Môi trường	Transaction cost / Slippage	0,1% / 0,05%
Mạng neural	Hidden dimension	256
PPO	Learning rate / Gamma / ϵ / Epochs	2e-4 / 0,99 / 0,2 / 8
CVaR-PPO	CVaR alpha / Lambda	0,15 / 0,15 $\rightarrow$ 0,08
Sortino-PPO	Sortino lambda	0,2
Huấn luyện	Episodes / Update interval / Device	300 / 256 steps / CUDA

4.5.2. Kết quả trong quá trình huấn luyện

Kết quả ghi nhận ở cuối quá trình huấn luyện 300 episodes. Cả ba mô hình đều đạt giá trị danh mục cao hơn vốn ban đầu 10.000 USD.

Bảng 8. Kết quả ghi nhận cuối quá trình huấn luyện

Mô hình	Avg Reward ep.300	Avg Portfolio ep.300	Final Portfolio
PPO	+0,3971	14.535,70 USD	12.434,05 USD
CVaR-PPO	+0,3410	13.652,02 USD	14.089,07 USD
Sortino-PPO	+0,3488	13.894,47 USD	13.060,67 USD

PPO có Avg Reward cao nhất ở episode 300, trong khi CVaR-PPO có Final Portfolio sau train cao nhất. Tuy nhiên, kết quả trên tập train chỉ phản ánh khả năng học trong môi trường huấn luyện; cần xem xét tập test để đánh giá hiệu quả thực nghiệm.

4.5.3. Kết quả đánh giá trên tập test 2023–2024

Sau khi huấn luyện, các mô hình được đánh giá trên SPY (tài sản chính) và hai tài sản bổ sung QQQ, GLD để kiểm tra khả năng tổng quát hóa.


Bảng 9. Kết quả đánh giá các mô hình trên tập test 2023–2024

Tài sản	Mô hình	Total Return	Sharpe Ratio	Max Drawdown	CVaR-95
SPY	PPO	+12,32%	0,920	-5,02%	-1,005%
SPY	CVaR-PPO	+21,80%	1,303	-6,55%	-1,169%
SPY	Sortino-PPO	+17,20%	1,110	-6,12%	-1,078%
SPY	Buy & Hold	+58,82%	1,884	-9,97%	-1,742%
QQQ	PPO	+39,64%	1,835	-8,18%	-1,285%
QQQ	CVaR-PPO	+46,14%	1,662	-8,11%	-1,637%
QQQ	Sortino-PPO	+41,24%	1,595	-7,57%	-1,572%
QQQ	Buy & Hold	+97,47%	2,004	-13,56%	-2,376%
GLD	PPO	+16,03%	1,002	-9,38%	-1,079%
GLD	CVaR-PPO	+13,04%	0,687	-9,26%	-1,491%
GLD	Sortino-PPO	+12,28%	0,746	-9,01%	-1,231%

GLD	Buy & Hold	+40,67%	1,281	-11,35%	-1,980%
-----	------------	---------	-------	---------	---------


4.5.4. Phân tích và so sánh với phương pháp đối chứng

Buy & Hold đạt Total Return cao nhất trên cả ba tài sản, phù hợp với bối cảnh tập test 2023–2024 là giai đoạn thị trường phục hồi và tăng trưởng mạnh. Tuy nhiên, chiến lược này đi kèm Max Drawdown và CVaR-95 lớn hơn các mô hình RL.




Hình 3. Đường giá trị danh mục của các chiến lược trên tập test 2023–2024

Trên SPY, CVaR-PPO đạt Total Return 21,80% và Sharpe Ratio 1,303, cao nhất trong nhóm mô hình RL. PPO có Max Drawdown thấp nhất (-5,02%), thể hiện khả năng kiểm soát sụt giảm danh mục tốt nhất. Các mô hình RL tăng chậm hơn Buy & Hold nhưng ổn định hơn, ít biến động hơn về drawdown.




Hình 4. So sánh các chỉ số đánh giá chính

CVaR-PPO và Sortino-PPO giữ đường vốn cao hơn PPO trong nhiều thời điểm nhờ cơ chế nhạy cảm rủi ro, giảm tác động của các cú giảm mạnh. Calmar Ratio cho thấy trade-off giữa lợi nhuận và mức sụt giảm lớn nhất; các mô hình RL có Calmar thấp hơn Buy & Hold nhưng ổn định hơn.



Hình 5. Drawdown theo phần trăm của các chiến lược trên tập test 2023–2024

Phân phối lợi nhuận hàng ngày cho thấy Buy & Hold có đuôi phân phối dày hơn ở phía âm, trong khi các mô hình RL kiểm soát rủi ro đuôi hiệu quả hơn — đặc biệt CVaR-PPO hạn chế được các ngày thua lỗ lớn.



Hình 6. Phân phối lợi nhuận hàng ngày của các mô hình RL và Buy & Hold

4.5.5. So sánh kết quả với các nghiên cứu khác

Bảng 10. So sánh kết quả thực nghiệm giữa hệ thống đề xuất và các nghiên cứu liên quan (trên tài sản SPY hoặc S&P 500, giai đoạn test tương đương)

Nghiên cứu	Phương pháp	Tài sản	Giai đoạn test	Total Return	Sharpe Ratio	Max Drawdown	Kiểm soát rủi ro
Đề tài này	PPO	SPY	2023 – 2024	+12,32 %	0,920	-5,02%	Trung lập
Đề tài này	CVaR-PPO	SPY	2023 – 2024	+21,80 %	1,303	-6,55%	Rủi ro đuôi (CVaR)
Đề tài này	Sortino-PPO	SPY	2023 – 2024	+17,20 %	1,110	-6,12%	Downside risk
Đề tài này	Buy & Hold	SPY	2023 – 2024	+58,82 %	1,884	-9,97%	Không
FinRL (Liu et al., 2020)	PPO (FinRL)	DJIA	2020 – 2021	+28,50 %	1,420	-8,30%	Trung lập
FinRL (Liu et al., 2020)	A2C (FinRL)	DJIA	2020 – 2021	+25,10 %	1,280	-9,10%	Trung lập
DeepTrader (Wang et al., 2021)	DRL + Market Condition	S&P 500	2019 – 2020	+18,60 %	1,150	-7,80%	Market-aware
CVaR-DRL (Cui et al., 2022)	CVaR-DRL	BTC/ETH	2021 – 2022	+15,40 %	0,890	-12,50%	CVaR penalty
DRL Ensemble (Yang et al., 2020)	Ensemble (PPO+A2C+DDPG)	DJIA	2019 – 2020	+32,70 %	1,560	-7,20%	Ensemble voting
MetaTrader (Niu et al., 2022)	Meta-RL Diverse Policy	S&P 500	2020 – 2021	+22,30 %	1,180	-8,90%	Meta-learning
Adaptive Portfolio (Almahdi & Yang, 2017)	RRL + MDD	S&P 500	2010 – 2016	+14,20 %	0,950	-6,80%	Max Drawdown


Cost-Sensitive (Zhang et al., 2020)	Cost-Sensitive DRL	CSI 300	2018 – 2019	+19,80 %	1,050	-10,20%	Transaction cost
-------------------------------------	--------------------	---------	-------------	----------	-------	---------	------------------

Bảng 11. Tổng hợp ưu điểm và nhược điểm của từng phương pháp


Phương pháp	Ưu điểm	Nhược điểm
PPO (Đề tài)	Max Drawdown thấp nhất (-5,02%) Ổn định, dễ triển khai	Total Return thấp nhất trong nhóm RL Không nhạy cảm rủi ro
CVaR-PPO (Đề tài)	Sharpe cao nhất nhóm RL (1,303) Kiểm soát rủi ro đuôi tốt	Total Return thấp hơn Buy & Hold Cần điều chỉnh λ CVaR
Sortino-PPO (Đề tài)	Cân bằng downside risk Giảm biến động bất lợi	Lợi nhuận thấp hơn CVaR-PPO Thận trọng trong thị trường tăng
FinRL PPO (Liu et al.)	Thư viện mã nguồn mở Hỗ trợ nhiều thuật toán	Không tích hợp risk-sensitive Phụ thuộc vào giai đoạn test
DeepTrader (Wang et al.)	Nhúng market condition Cân bằng risk-return	Kiến trúc phức tạp Khó tái tạo kết quả
DRL Ensemble (Yang et al.)	Sharpe cao (1,560) Giảm phương sai bằng voting	Cần train nhiều mô hình Chi phí tính toán cao
CVaR-DRL Crypto (Cui et al.)	Áp dụng CVaR cho crypto Kiểm soát tail risk	Max Drawdown cao (-12,50%) Chỉ thử nghiệm trên crypto
MetaTrader (Niu et al.)	Meta-learning đa chiến lược Linh hoạt	Phức tạp triển khai Cần nhiều dữ liệu huấn luyện

4.5.5. Demo web Django

Hệ thống được triển khai dưới dạng web demo bằng Django, cung cấp các chức năng: tạo tín hiệu giao dịch theo thời gian thực cho bất kỳ tài sản nào, chạy backtest với cấu hình tùy chỉnh, và so sánh trực quan các chiến lược trên cùng một giai đoạn.



Hình 7. Giao diện tổng quan của Web App Django



Hình 8. Biểu đồ chi tiết hiệu suất và rủi ro trên web demo

5. KẾT LUẬN

Nghiên cứu này đã đề xuất và triển khai thành công hệ thống giao dịch định lượng sử dụng học tăng cường nhạy cảm rủi ro với ba mô hình PPO, CVaR-PPO và Sortino-PPO. Kết quả thực nghiệm trên SPY, QQQ và GLD trong giai đoạn 2023–2024 cho thấy:

- Các mô hình RL học được chính sách giao dịch hiệu quả, vượt vốn ban đầu 10.000 USD, đồng thời kiểm soát rủi ro tốt hơn chiến lược Buy & Hold về mặt Max Drawdown và CVaR-95.
- Buy & Hold mang lại lợi nhuận tuyệt đối cao nhất trong giai đoạn thị trường tăng mạnh, nhưng đi kèm biến động lớn, Max Drawdown và rủi ro đuôi cao hơn.
- CVaR-PPO đạt Total Return và Sharpe Ratio cao nhất trong nhóm RL trên SPY (+21,80%, Sharpe 1,303), cho thấy hiệu quả của việc kiểm soát rủi ro đuôi trong quá trình huấn luyện.
- Sortino-PPO hạn chế được biến động bất lợi, cải thiện độ ổn định danh mục trong các giai đoạn thị trường bất lợi.

Hạn chế: các mô hình RL phụ thuộc dữ liệu huấn luyện, yêu cầu tối ưu nhiều tham số và chưa tối ưu hoàn toàn lợi nhuận tuyệt đối. Kết quả backtest phụ thuộc vào dữ liệu, giai đoạn kiểm thử, cấu hình mô hình và giả định chi phí giao dịch.

Hướng phát triển trong tương lai bao gồm: mở rộng đánh giá trên nhiều tài sản và thị trường; thử nghiệm kiểm thử walk-forward; triển khai paper trading để kiểm tra độ ổn định trong điều kiện gần thực tế; kết hợp các chỉ số rủi ro bổ sung vào hàm reward; và tích hợp dữ liệu sentiment thị trường.

TÀI LIỆU THAM KHẢO

- [1] Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017). Proximal Policy Optimization Algorithms. arXiv:1707.06347.
- [2] Rockafellar, R. T., & Uryasev, S. (2000). Optimization of Conditional Value-at-Risk. *Journal of Risk*, 2(3), 21–42.
- [3] Moody, J., & Saffell, M. (2001). Learning to Trade via Direct Reinforcement. *IEEE Transactions on Neural Networks*, 12(4), 875–889.
- [4] Tesauro, G. (1995). Temporal Difference Learning and TD-Gammon. *Communications of the ACM*, 38(3), 58–68.
- [5] Jiang, Z., Xu, D., & Liang, J. (2017). A Deep Reinforcement Learning Framework for the Financial Portfolio Management Problem. arXiv:1712.10018.
- [6] Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2nd ed.). MIT Press.
- [7] Théate, T., & Ernst, D. (2021). An application of deep reinforcement learning to algorithmic trading. *Expert Systems with Applications*, 173, 114632.
- [8] Jiang, Y., Olmo, J., & Atwi, M. (2024). Deep reinforcement learning for portfolio selection. *Global Finance Journal*.

- [9] Shavandi, A., & Khedmati, M. (2022). A multi-agent deep reinforcement learning framework for algorithmic trading in financial markets. *Expert Systems with Applications*, 200, 116959.
- [10] Kabbani, T., & Duman, E. (2022). Deep Reinforcement Learning Approach for Trading Automation in the Stock Market. *IEEE Access*, 10, 76612–76627.
- [11] Cui, T., Du, N., Yang, X., & Ding, S. (2024). Multi-period portfolio optimization using a deep reinforcement learning hyper-heuristic approach. *Technological Forecasting and Social Change*, 193, 122589.
- [12] Bühler, H., Gonon, L., Teichmann, J., & Wood, B. (2019). Deep hedging. *Quantitative Finance*, 19(8), 1271–1291.
- [13] Liu, X.-Y., Yang, H., Chen, Q., Zhang, R., Yang, L., Xiao, B., & Wang, C. (2020). FinRL: A Deep Reinforcement Learning Library for Automated Stock Trading in Quantitative Finance. *arXiv preprint arXiv:2011.09607*.
- [14] Lu, C. I. (2023). Evaluation of Deep Reinforcement Learning Algorithms for Portfolio Optimisation. *arXiv preprint arXiv:2307.07407*.
- [15] Aritonang, P. K., Wiryono, S. K., & Fatur Rahman, T. (2024). Hidden-layer configurations in reinforcement learning models for stock portfolio optimization. *Intelligent Systems with Applications*, 20, 200347.
- [16] Sortino, F., & Price, L. (1994). Performance Measurement in a Downside Risk Framework. *Journal of Investing*, 3(3), 59–64.
- [17] Liang, Z., Chen, H., Zhu, J., Jiang, K., & Li, Y. (2018). Adversarial Deep Reinforcement Learning in Portfolio Management. *arXiv: Portfolio Management*.
- [18] Yang, H., Liu, X., Zhong, S., & Walid, A. (2020). Deep reinforcement learning for automated stock trading: an ensemble strategy. *Proceedings of the First ACM International Conference on AI in Finance*.
- [19] Cui, T., Ding, S., Jin, H., & Zhang, Y. (2022). Portfolio constructions in cryptocurrency market: A CVaR-based deep reinforcement learning approach. *Economic Modelling*. <https://doi.org/10.1016/j.econmod.2022.106078>.
- [20] Aboussalah, A., & Lee, C. (2020). Continuous control with Stacked Deep Dynamic Recurrent Reinforcement Learning for portfolio optimization. *Expert Systems with Applications*, 140. <https://doi.org/10.1016/j.eswa.2019.112891>.
- [21] Alameer, A., & Alshehri, K. (2021). Conditional Value-at-Risk for Quantitative Trading: A Direct Reinforcement Learning Approach. *2022 IEEE Conference on Control Technology and Applications (CCTA)*, 1208–1213. <https://doi.org/10.1109/ccta49430.2022.9966017>.
- [22] Jang, J., & Seong, N. (2023). Deep reinforcement learning for stock portfolio optimization by connecting with modern portfolio theory. *Expert Systems with Applications*, 218, 119556. <https://doi.org/10.1016/j.eswa.2023.119556>.
- [23] Wang, Z., Huang, B., Tu, S., Zhang, K., & Xu, L. (2021). DeepTrader: A Deep Reinforcement Learning Approach for Risk-Return Balanced Portfolio Management with

Market Conditions Embedding. AAAI 2021, 643–650.

<https://doi.org/10.1609/aaai.v35i1.16144>.

[24] Zhang, Y., Zhao, P., Wu, Q., Li, B., Huang, J., & Tan, M. (2020). Cost-Sensitive Portfolio Selection via Deep Reinforcement Learning. *IEEE Transactions on Knowledge and Data Engineering*, 34, 236–248. <https://doi.org/10.1109/tkde.2020.2979700>.

[25] Niu, H., Li, S., & Li, J. (2022). MetaTrader: An Reinforcement Learning Approach Integrating Diverse Policies for Portfolio Optimization. *Proceedings of the 31st ACM International Conference on Information & Knowledge Management*.

<https://doi.org/10.1145/3511808.3557363>.

[26] Almahdi, S., & Yang, S. (2017). An adaptive portfolio trading system: A risk-return portfolio optimization using recurrent reinforcement learning with expected maximum drawdown. *Expert Systems with Applications*, 87, 267–279.

<https://doi.org/10.1016/j.eswa.2017.06.023>.

[27] Sun, Q., Wei, X., & Yang, X. (2023). GraphSAGE with deep reinforcement learning for financial portfolio optimization. *Expert Systems with Applications*, 238, 122027.

<https://doi.org/10.1016/j.eswa.2023.122027>.