

TRƯỜNG ĐẠI HỌC CÔNG NGHIỆP TP HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN



ĐỒ ÁN CUỐI KÌ
GIAO DỊCH ĐỊNH LƯỢNG

Người thực hiện: **NGUYỄN NGỌC LÂN – 22635801**

LÊ HUỲNH TẤN ĐẠT – 23634031

Lớp : **420301411301**

Khoá : **19**

Người hướng dẫn: **TS. BÙI THANH HÙNG**

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

TRƯỜNG ĐẠI HỌC CÔNG NGHIỆP TP HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN



ĐỒ ÁN CUỐI KÌ
GIAO DỊCH ĐỊNH LƯỢNG

Người thực hiện: **NGUYỄN NGỌC LÂN- 22635801**
LÊ HUỲNH TẤN ĐẠT- 23634031

Lớp : **420301411301**

Khoá : **19**

Người hướng dẫn: **TS. BÙI THANH HÙNG**

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

LỜI CẢM ƠN

Chúng em xin gửi lời cảm ơn chân thành đến TS. Bùi Thanh Hùng, giảng viên hướng dẫn môn Giao dịch định lượng, đã định hướng và hỗ trợ nhóm trong quá trình thực hiện đồ án cuối kỳ. Những kiến thức được học trong môn học đã giúp nhóm em có cơ sở để tiếp cận bài toán giao dịch định lượng, đặc biệt là việc đánh giá chiến lược giao dịch không chỉ dựa trên lợi nhuận mà còn dựa trên các yếu tố rủi ro.

Trong quá trình thực hiện đề tài, chúng em có cơ hội tìm hiểu và xây dựng một hệ thống thử nghiệm các mô hình học tăng cường cho bài toán giao dịch tài chính, bao gồm PPO, CVaR-PPO, Sortino-PPO và phương pháp Buy & Hold làm chuẩn so sánh. Thông qua việc xử lý dữ liệu thị trường, xây dựng quy trình backtest và phân tích các chỉ số như Total Return, Sharpe Ratio, Max Drawdown và Volatility, nhóm hiểu rõ hơn vai trò của quản trị rủi ro trong giao dịch định lượng.

Chúng em cũng xin cảm ơn Khoa Công nghệ Thông tin, Trường Đại học Công nghiệp Thành phố Hồ Chí Minh đã tạo điều kiện học tập và cung cấp môi trường để vận dụng kiến thức chuyên ngành vào quá trình thực hiện đồ án.

Do thời gian thực hiện và kinh nghiệm nghiên cứu còn hạn chế, đồ án khó tránh khỏi những thiếu sót. Nhóm chúng em rất mong nhận được sự góp ý của Thầy để có thể tiếp tục hoàn thiện đề tài tốt hơn trong tương lai.

Chúng em xin chân thành cảm ơn.

ĐỒ ÁN ĐƯỢC HOÀN THÀNH TẠI TRƯỜNG ĐẠI HỌC CÔNG NGHIỆP TP HỒ CHÍ MINH

Tôi xin cam đoan đây là sản phẩm đồ án của riêng tôi / chúng tôi và được sự hướng dẫn của TS. Bùi Thanh Hùng. Các nội dung nghiên cứu, kết quả trong đề tài này là trung thực và chưa công bố dưới bất kỳ hình thức nào trước đây. Những số liệu trong các bảng biểu phục vụ cho việc phân tích, nhận xét, đánh giá được chính tác giả thu thập từ các nguồn khác nhau có ghi rõ trong phần tài liệu tham khảo.

Ngoài ra, trong đồ án còn sử dụng một số nhận xét, đánh giá cũng như số liệu của các tác giả khác, cơ quan tổ chức khác đều có trích dẫn và chú thích nguồn gốc.

Nếu phát hiện có bất kỳ sự gian lận nào tôi xin hoàn toàn chịu trách nhiệm về nội dung đồ án của mình. Trường đại học Công nghiệp TP Hồ Chí Minh không liên quan đến những vi phạm tác quyền, bản quyền do tôi gây ra trong quá trình thực hiện (nếu có).

TP. Hồ Chí Minh, ngày tháng năm

Tác giả

(ký tên và ghi rõ họ tên)

Nguyễn Ngọc Lân

Lê Huỳnh Tấn Đạt

PHẦN ĐÁNH GIÁ CỦA GIẢNG VIÊN

Tp. Hồ Chí Minh, ngày tháng năm
(kí và ghi họ tên)

TÓM TẮT

Giao dịch định lượng là bài toán ra quyết định theo chuỗi thời gian, trong đó mỗi hành động mua, bán hoặc nắm giữ tài sản đều ảnh hưởng đến trạng thái danh mục ở các thời điểm tiếp theo. Vì vậy, việc đánh giá một chiến lược giao dịch không nên chỉ dựa trên lợi nhuận tuyệt đối mà cần xem xét thêm các yếu tố rủi ro như biến động lợi nhuận, mức sụt giảm tối đa và rủi ro trong các giai đoạn thị trường bất lợi.

Đề tài này xây dựng một hệ thống thử nghiệm giao dịch định lượng sử dụng học tăng cường sâu theo hướng nhạy cảm rủi ro. Hệ thống không dự báo trực tiếp giá cổ phiếu, mà học chính sách giao dịch dựa trên trạng thái thị trường và trạng thái danh mục. Các mô hình được triển khai và so sánh gồm PPO, CVaR-PPO, Sortino-PPO và chiến lược Buy & Hold làm chuẩn đối chiếu. Trong đó, PPO đóng vai trò mô hình cơ sở trung lập rủi ro, CVaR-PPO hướng đến kiểm soát rủi ro đuôi, còn Sortino-PPO tập trung vào biến động bất lợi của lợi nhuận.

Quy trình thực hiện bao gồm thu thập dữ liệu thị trường, xử lý dữ liệu OHLCV, xây dựng các chỉ báo kỹ thuật, chuẩn hóa đặc trưng, tạo trạng thái đầu vào, sinh hành động giao dịch và tiến hành backtest. Hệ thống được triển khai dưới dạng web demo bằng Django, hỗ trợ tạo tín hiệu giao dịch theo thời gian thực, chạy backtest và so sánh hiệu quả giữa các mô hình. Kết quả được đánh giá bằng các chỉ số như Total Return, Sharpe Ratio, Sortino Ratio, Max Drawdown, Volatility, Win Rate và Number of Trades.

Kết quả thực nghiệm trên artifact hiện có cho thấy Buy & Hold đạt lợi nhuận tuyệt đối cao nhất trong giai đoạn kiểm thử 2023–2024, phù hợp với bối cảnh thị trường tăng mạnh. Tuy nhiên, các mô hình học tăng cường vẫn có ý nghĩa trong việc phân tích sự đánh đổi giữa lợi nhuận và rủi ro. PPO có mức Max Drawdown thấp nhất trong bảng tổng hợp, trong khi CVaR-PPO đạt Total Return, Sharpe Ratio và Sortino Ratio cao hơn

PPO trong artifact kiểm thử. Điều này cho thấy việc đánh giá chiến lược giao dịch cần xem xét đồng thời nhiều chỉ số thay vì chỉ dựa vào lợi nhuận cuối kỳ.

Đề tài mang tính chất nghiên cứu và demo học thuật, không phải hệ thống giao dịch thực tế hay khuyến nghị đầu tư. Kết quả backtest phụ thuộc vào dữ liệu, giai đoạn kiểm thử, cấu hình mô hình và giả định chi phí giao dịch. Trong tương lai, hệ thống có thể được mở rộng theo hướng kiểm thử walk-forward, đánh giá trên nhiều tài sản và triển khai paper trading để kiểm tra độ ổn định trong điều kiện gần thực tế hơn.

MỤC LỤC

LỜI CẢM ƠN	i
PHẦN ĐÁNH GIÁ CỦA GIẢNG VIÊN.....	iii
TÓM TẮT	iv
MỤC LỤC	1
DANH MỤC KÍ HIỆU VÀ CHỮ VIẾT TẮT.....	4
DANH MỤC CÁC BẢNG	7
CHƯƠNG 1. GIỚI THIỆU VỀ BÀI TOÁN	8
1.1 Giới thiệu về bài toán.....	8
1.2 Ý nghĩa của bài toán	9
CHƯƠNG 2. PHÂN TÍCH YÊU CẦU CỦA BÀI TOÁN	10
2.1 Yêu cầu của bài toán.....	10
2.2 Các phương pháp giải quyết bài toán	11
2.2.1. Chiến lược Buy & Hold.	11
2.2.2. Học tăng cường trong giao dịch tài chính.....	11
2.2.3. Deep Reinforcement Learning cho quản lý danh mục.	12
2.2.4. Proximal Policy Optimization (PPO).	13
2.2.5. Conditional Value at Risk (CVaR).....	13
2.2.6. Sortino Ratio và Downside Risk.	14
2.3 Phương pháp đề xuất giải quyết bài toán.....	15
2.3.1. Chiến lược cơ sở (Buy & Hold)	15
2.3.2. Học tăng cường trực tiếp (Direct Reinforcement Learning - RRL)	
15	
2.3.3. Học tăng cường sâu cho quản lý danh mục (Deep Reinforcement Learning - FRL).....	16

2.3.4. Proximal Policy Optimization (PPO)	16
2.3.5. Conditional Value at Risk (CVaR-PPO)	16
2.3.6. Sortino-PPO (Downside Risk):	16
CHƯƠNG 3. PHƯƠNG PHÁP ĐỀ XUẤT	17
3.1. Mô hình tổng quát.....	17
3.1.1. Data Collection (Thu thập dữ liệu).....	18
3.1.2. Data Preprocessing & Feature Extraction (Tiền xử lý và trích xuất đặc trưng).....	19
3.1.3. Reinforcement Learning Environment (Môi trường học tăng cường) 19	
3.1.5. Outputs / Evaluation (Kết quả và đánh giá).....	19
3.2 Xử lý dữ liệu và trích xuất đặc trưng.....	20
3.2.1. Cào dữ liệu.....	20
3.2.2 Trích xuất đặc trưng	21
3.3 Môi trường giao dịch và mô hình hóa bài toán	25
3.3.1 Không gian hành động	26
3.3.2 Chi phí giao dịch và trượt giá	27
3.3.3 Hàm phần thưởng.....	27
3.4 Các mô hình học tăng cường được sử dụng.....	28
3.5 Quy trình huấn luyện và suy luận.....	29
CHƯƠNG 4. THỰC NGHIỆM	31
4.1 Dữ liệu.....	31
4.2 Xử lý dữ liệu.....	32
4.3 Công nghệ sử dụng	33
4.4 Cách đánh giá	34
4.5 Kết quả đạt được.....	36
4.5.1 Thiết lập tham số thực nghiệm.....	36

4.5.2 Kết quả trong quá trình huấn luyện.....	37
4.5.3 Kết quả đánh giá trên tập test.....	37
4.5.4 So sánh với phương pháp đối chứng.....	39
4.5.5. So sánh kết quả với các nghiên cứu khác	45
4.6 Giao diện Web Demo.....	47
CHƯƠNG 5. KẾT LUẬN	50
5.1 Kết luận	50
5.2 Hướng phát triển	50
TÀI LIỆU THAM KHẢO	51
PHỤ LỤC.....	54
LÀM VIỆC NHÓM.....	55
TỰ ĐÁNH GIÁ.....	59

DANH MỤC KÍ HIỆU VÀ CHỮ VIẾT TẮT

CÁC KÝ HIỆU

Ký hiệu	Diễn giải
t	Chỉ số thời gian trong chuỗi dữ liệu giao dịch
s_t	Trạng thái của môi trường tại thời điểm t
a_t	Hành động giao dịch tại thời điểm t
R_t	Reward tại thời điểm t
V_t	Giá trị danh mục tại thời điểm t
B_t	Số dư tiền mặt tại thời điểm t
Q_t	Số lượng tài sản đang nắm giữ tại thời điểm t
P_t	Giá tài sản tại thời điểm t
B_0	Vốn khởi tạo ban đầu

CÁC CHỮ VIẾT TẮT

Chữ viết tắt	Diễn giải
DRL	Deep Reinforcement Learning
RL	Reinforcement Learning
PPO	Proximal Policy Optimization
CVaR	Conditional Value at Risk
OHLCV	Open, High, Low, Close, Volume

SMA	Simple Moving Average
RSI	Relative Strength Index
MACD	Moving Average Convergence Divergence
ATR	Average True Range
API	Application Programming Interface

DANH MỤC CÁC HÌNH VẼ

Hình 3.1: Quy trình tổng thể hệ thống RL cho giao dịch định lượng.....	18
Hình 3.2: Quy trình thu thập và tiền xử lý dữ liệu thị trường.....	21
Hình 4.1: Đường giá trị danh mục của các chiến lược trên tập test 2023–2024.	40
Hình 4.2: So sánh các chỉ số đánh giá chính của các mô hình học tăng cường và chiến lược Buy & Hold trên tập test 2023–2024.....	41
Hình 4.3: Drawdown theo phần trăm của các chiến lược trên tập test 2023–2024	42
Hình 4.4: Phân phối lợi nhuận hàng ngày của các mô hình RL và Buy & Hold.....	43
Hình 4.5: Giao diện tổng quan của Web App.....	48
Hình 4.6: Biểu đồ chi tiết hiệu suất và rủi ro.....	49

DANH MỤC CÁC BẢNG

Bảng 3.1: Giá trị khởi tạo của danh mục đầu tư.....	23
Bảng 3.2: Dữ liệu thị trường thô (OHLCV)	24
Bảng 3.3: Các đặt trưng tính toán.....	25
Bảng 3.4: Các biến danh mục.....	25
Bảng 3.5: Tóm tắt vai trò của từng mô hình trong hệ thống đề xuất.	29
Bảng 3.6: Sự khác biệt trong quá trình huấn luyện giữa các mô hình	30
Bảng 4.1: Phân chia tập dữ liệu và vai trò từng giai đoạn.....	32
Bảng 4.2: Vai trò và ý nghĩa các tài sản trong thực nghiệm.....	32
Bảng 4.3: Các bước xử lý dữ liệu và mục đích.....	33
Bảng 4.4: Các chỉ số đo lường hiệu quả chiến lược giao dịch.....	35
Bảng 4.5: Kết quả ghi nhận cuối quá trình huấn luyện	37
Bảng 4.6: Kết quả ghi nhận cuối quá trình huấn luyện	38
Bảng 4.7: Kết quả đánh giá các mô hình trên tập test 2023–2024.....	41
Bảng 4.8: So sánh kết quả thực nghiệm giữa hệ thống đề xuất và các nghiên cứu liên quan (trên tài sản SPY hoặc S&P 500, giai đoạn test tương đương)	46
Bảng 4.9: Tổng hợp ưu điểm và nhược điểm của từng phương pháp	47

CHƯƠNG 1. GIỚI THIỆU VỀ BÀI TOÁN

1.1 Giới thiệu về bài toán

Đề tài Risk-Sensitive Reinforcement Learning for Trading tập trung xây dựng một hệ thống thử nghiệm giao dịch định lượng sử dụng học tăng cường sâu. Hệ thống không dự báo trực tiếp giá cổ phiếu, mà học chính sách giao dịch dựa trên trạng thái thị trường và trạng thái danh mục. Từ trạng thái đầu vào, mô hình sinh ra một hành động liên tục, sau đó hành động này được diễn giải thành tín hiệu BUY, SELL hoặc HOLD trong quá trình demo và backtest.

Bài toán được mô hình hóa theo hướng ra quyết định tuần tự. Ở mỗi thời điểm giao dịch, hệ thống quan sát dữ liệu thị trường, các chỉ báo kỹ thuật và thông tin danh mục hiện tại. Dựa trên trạng thái này, policy quyết định mức độ mua, bán hoặc giữ tài sản. Quyết định tại một thời điểm sẽ ảnh hưởng đến trạng thái danh mục ở các thời điểm sau, do đó bài toán không chỉ phụ thuộc vào biến động giá mà còn phụ thuộc vào cách quản lý vị thế và rủi ro.

Trong phạm vi đề tài, các mô hình được so sánh gồm PPO, CVaR-PPO, Sortino-PPO và chiến lược Buy & Hold. PPO được dùng như mô hình cơ sở trung lập rủi ro. CVaR-PPO bổ sung góc nhìn về rủi ro đuôi, tức các trường hợp lợi nhuận bất lợi. Sortino-PPO tập trung vào biến động bất lợi của lợi nhuận. Buy & Hold được sử dụng làm benchmark thụ động để đối chiếu với các chính sách học tăng cường.

Hệ thống được triển khai dưới dạng web demo bằng Django, hỗ trợ các chức năng chính gồm tạo tín hiệu giao dịch theo thời gian thực, chạy backtest và so sánh kết quả giữa các mô hình. Kết quả đánh giá được trình bày thông qua các chỉ số như Total Return, Sharpe Ratio, Sortino Ratio, Max Drawdown, Volatility, Win Rate và Number of Trades. Đề tài chỉ phục vụ mục đích học thuật và thực nghiệm, không phải hệ thống giao dịch thật hay khuyến nghị đầu tư.

1.2 Ý nghĩa của bài toán

Ý nghĩa chính của bài toán nằm ở việc đánh giá chiến lược giao dịch không chỉ dựa trên lợi nhuận cuối kỳ mà còn dựa trên mức độ rủi ro đi kèm. Trong thực tế, một chiến lược có lợi nhuận cao vẫn có thể kém ổn định nếu có Max Drawdown lớn hoặc Volatility cao. Vì vậy, việc so sánh các mô hình theo nhiều chỉ số rủi ro/lợi nhuận giúp đánh giá chiến lược một cách đầy đủ hơn.

Về mặt học thuật, đề tài giúp minh họa sự khác biệt giữa chính sách giao dịch trung lập rủi ro và chính sách nhạy cảm rủi ro. PPO đại diện cho hướng tối ưu lợi nhuận kỳ vọng, trong khi CVaR-PPO và Sortino-PPO đưa thêm yếu tố rủi ro vào quá trình huấn luyện hoặc định hình reward. Việc đặt các mô hình này trong cùng một môi trường backtest giúp phân tích rõ hơn sự đánh đổi giữa lợi nhuận, drawdown và biến động danh mục.

Về mặt triển khai, đề tài xây dựng được một quy trình thực nghiệm gồm xử lý dữ liệu thị trường, tạo chỉ báo kỹ thuật, chuẩn hóa đặc trưng, xây dựng trạng thái, sinh hành động giao dịch và đánh giá kết quả bằng backtest. Web demo giúp trực quan hóa kết quả và hỗ trợ so sánh các mô hình trên cùng một giai đoạn dữ liệu.

Tuy nhiên, kết quả của hệ thống cần được diễn giải thận trọng. Backtest phụ thuộc vào dữ liệu, giai đoạn kiểm thử, cấu hình mô hình, chi phí giao dịch và slippage. Do đó, giá trị chính của đề tài là minh họa cách xây dựng và đánh giá các chính sách giao dịch học tăng cường có xét đến rủi ro, chứ không nhằm khẳng định mô hình có thể tạo lợi nhuận ổn định trong giao dịch thực tế.

CHƯƠNG 2. PHÂN TÍCH YÊU CẦU CỦA BÀI TOÁN

2.1 Yêu cầu của bài toán

Bài toán của đề tài là xây dựng một hệ thống thử nghiệm giao dịch định lượng sử dụng học tăng cường sâu, trong đó mô hình sinh hành động giao dịch dựa trên trạng thái thị trường và trạng thái danh mục. Hệ thống không dự báo trực tiếp giá cổ phiếu, mà học chính sách giao dịch để quyết định mức độ mua, bán hoặc nắm giữ tài sản tại từng thời điểm.

Dữ liệu đầu vào của hệ thống bao gồm mã tài sản cần phân tích, khoảng thời gian backtest, số vốn ban đầu và mô hình được chọn để sinh tín hiệu giao dịch. Dữ liệu thị trường được lấy dưới dạng OHLCV, gồm giá mở cửa, giá cao nhất, giá thấp nhất, giá đóng cửa và khối lượng giao dịch. Từ dữ liệu này, hệ thống xây dựng thêm các chỉ báo kỹ thuật như SMA, RSI, MACD, Bollinger Bands, ATR, returns, log returns và volume SMA để tạo đặc trưng đầu vào cho mô hình.

Đầu ra của hệ thống gồm hành động giao dịch liên tục do policy sinh ra, tín hiệu BUY, SELL hoặc HOLD, đường giá trị danh mục, chuỗi drawdown và các chỉ số đánh giá hiệu quả giao dịch. Các chỉ số chính bao gồm Total Return, Sharpe Ratio, Sortino Ratio, Max Drawdown, Volatility, Win Rate và Number of Trades. Các chỉ số này giúp đánh giá chiến lược trên cả hai khía cạnh lợi nhuận và rủi ro.

Về yêu cầu chức năng, hệ thống cần hỗ trợ ba nhóm chức năng chính. Thứ nhất là tạo tín hiệu giao dịch theo thời gian thực dựa trên mô hình được chọn. Thứ hai là chạy backtest để đánh giá hiệu quả của các mô hình trên dữ liệu lịch sử. Thứ ba là so sánh PPO, CVaR-PPO, Sortino-PPO và Buy & Hold trên cùng một giai đoạn dữ liệu để quan sát sự khác biệt giữa các chiến lược.

Về yêu cầu phi chức năng, hệ thống cần đảm bảo dữ liệu được xử lý nhất quán giữa quá trình huấn luyện và quá trình suy luận. Các tham số chuẩn hóa đặc trưng phải được lấy từ giai đoạn huấn luyện, không tính lại trên dữ liệu test hoặc dữ liệu realtime nhằm giảm nguy cơ data leakage. Ngoài ra, kết quả backtest cần được trình bày kèm thông tin về symbol, giai đoạn dữ liệu, vốn ban đầu, chi phí giao dịch và slippage để việc diễn giải kết quả rõ ràng hơn.

2.2 Các phương pháp giải quyết bài toán

Trong giao dịch định lượng, có nhiều hướng tiếp cận để xây dựng và đánh giá chiến lược giao dịch. Với phạm vi đề tài này, các phương pháp liên quan được xem xét gồm chiến lược Buy & Hold, học tăng cường trong giao dịch tài chính, PPO, CVaR và Sortino Ratio. Các phương pháp này được chọn vì có liên quan trực tiếp đến cách hệ thống trong đề tài xây dựng policy giao dịch, đánh giá rủi ro và so sánh kết quả thực nghiệm.

2.2.1. Chiến lược Buy & Hold.

Buy & Hold là chiến lược đầu tư thụ động, trong đó nhà đầu tư mua tài sản ở thời điểm đầu và nắm giữ đến cuối giai đoạn đánh giá. Phương pháp này đơn giản, dễ hiểu và thường được sử dụng làm benchmark trong các bài toán giao dịch. Tuy nhiên, Buy & Hold không điều chỉnh vị thế theo trạng thái thị trường nên có thể chịu mức sụt giảm lớn trong các giai đoạn thị trường giảm mạnh. Trong đề tài này, Buy & Hold được sử dụng làm chuẩn đối chiếu để đánh giá các chính sách học tăng cường.

2.2.2. Học tăng cường trong giao dịch tài chính.

Trong bài báo “*Learning to Trade via Direct Reinforcement*”, Moody và Saffell (2001) đề xuất sử dụng thuật toán Recurrent Reinforcement Learning (RRL) để học trực tiếp chiến lược giao dịch và tối ưu hiệu suất đầu tư thay vì xây dựng mô hình dự báo giá trước rồi ra quyết định giao dịch. Phương pháp này xem bài toán đầu tư như một bài toán

điều khiển ngẫu nhiên (stochastic control), loại bỏ nhu cầu xây dựng mô hình dự báo và tránh “curse of dimensionality” khi sử dụng các phương pháp Q-learning/TD-learning.

Trong các thử nghiệm mô phỏng với dữ liệu tài chính thực tế, phương pháp RRL được chứng minh tạo ra chiến lược giao dịch tốt hơn so với các hệ thống sử dụng Q-learning – đặc biệt trên các chỉ tiêu điều chỉnh theo rủi ro như differential Sharpe ratio – và vẫn tính đến chi phí giao dịch. Mô hình RRL đã được áp dụng thành công cho các ứng dụng thực tế như giao dịch nội ngày cặp tiền ngoại hối (FX) và phân bổ danh mục dựa trên chỉ số S&P 500 và trái phiếu T-Bills.

Tuy nhiên, hạn chế của hướng tiếp cận này là hiệu quả mô hình có thể phụ thuộc mạnh vào dữ liệu huấn luyện, giả định về chi phí giao dịch và khả năng tổng quát hóa sang các thị trường/kỳ khác nhau, do chiến lược học trực tiếp chính sách dựa trên dữ liệu lịch sử có thể không luôn phản ánh được tính phi tuyến, non-stationary trong dữ liệu tài chính thực tế.

2.2.3. Deep Reinforcement Learning cho quản lý danh mục.

Trong bài báo “*A Deep Reinforcement Learning Framework for the Financial Portfolio Management Problem*”, Jiang, Xu và Liang (2017) đề xuất một framework deep reinforcement learning có tên Financial Reinforcement Learning (FRL) để giải quyết bài toán quản lý danh mục đầu tư đa tài sản. Bài báo mô hình hóa bài toán phân bổ vốn như một quá trình tuần tự, sử dụng các đặc trưng thị trường (OHLCV và chỉ báo kỹ thuật) làm trạng thái và huấn luyện policy network để phân bổ vốn giữa các tài sản nhằm tối ưu tổng lợi nhuận trong quá trình huấn luyện.

Trong các thử nghiệm thực nghiệm, tác giả áp dụng mô hình FRL trên dữ liệu lịch sử cổ phiếu của sàn NYSE & NASDAQ với nhiều cổ phiếu khác nhau và so sánh hiệu suất với các benchmark truyền thống như Uniform Buy & Hold và Mean-Variance Portfolio. Kết quả cho thấy mô hình FRL đạt tổng lợi nhuận lớn hơn so với các chiến

lược benchmark, đồng thời giảm đáng kể downside volatility và max drawdown trong nhiều giai đoạn thực nghiệm, đặc biệt khi thị trường có biến động mạnh. Những kết quả này chứng minh khả năng học chính sách phân bổ vốn trực tiếp từ dữ liệu thị trường, đồng thời cung cấp một phương pháp quản lý danh mục hiệu quả hơn các cách tiếp cận cổ điển trong nhiều kịch bản kiểm thử.

Tuy nhiên, hạn chế của công trình là phạm vi thử nghiệm chủ yếu trên dữ liệu lịch sử cố định, có thể dẫn tới overfitting khi triển khai ngoài mẫu, và mô hình yêu cầu số lượng tài sản đủ lớn mới khai thác được hết tiềm năng học sâu, nên không hoàn toàn tương thích nếu dữ liệu đầu vào chỉ có 1 tài sản duy nhất — trường hợp chính của đề tài này.

2.2.4. Proximal Policy Optimization (PPO).

Trong bài báo “*Proximal Policy Optimization Algorithms*”, Schulman và cộng sự (2017) đề xuất PPO nhằm cải thiện độ ổn định của quá trình cập nhật policy bằng cách giới hạn mức thay đổi giữa policy mới và policy cũ. PPO là một phương pháp tương đối dễ triển khai, ổn định hơn so với các thuật toán policy gradient truyền thống và phù hợp với không gian hành động liên tục.

Trong các thử nghiệm mô phỏng, PPO được chứng minh giữ ổn định reward và cải thiện tốc độ hội tụ so với các thuật toán baseline, đặc biệt trong các bài toán liên quan đến học policy liên tục. Trong đề tài này, PPO được sử dụng làm baseline trung lập rủi ro để so sánh với các biến thể nhảy cảm rủi ro như CVaR-PPO và Sortino-PPO, cũng như so sánh với chiến lược Buy & Hold.

Hạn chế của PPO trong trading là nếu chỉ tối ưu expected reward, mô hình có thể chưa kiểm soát tốt các rủi ro như drawdown, volatility hoặc tail risk.

2.2.5. Conditional Value at Risk (CVaR).

Trong bài báo “*Optimization of Conditional Value-at-Risk*”, Rockafellar và Uryasev (1999) trình bày phương pháp tối ưu CVaR, một thước đo tập trung vào phần đuôi xấu của phân phối tổn thất. CVaR không chỉ quan tâm đến ngưỡng rủi ro như VaR, mà còn xem xét mức tổn thất kỳ vọng trong các trường hợp xấu nhất, giúp đánh giá rủi ro cực đoan trong danh mục đầu tư.

Trong các thử nghiệm trên dữ liệu thị trường giả lập, tối ưu hóa CVaR giúp giảm tail loss đáng kể so với các chiến lược tối ưu reward kỳ vọng, đồng thời cải thiện khả năng kiểm soát rủi ro tổng thể. Trong đề tài này, ý tưởng CVaR được kết hợp vào CVaR-PPO, nhằm đưa yếu tố tail risk vào quá trình huấn luyện policy, giúp chiến lược học tăng cường cân bằng giữa tối ưu lợi nhuận và quản lý rủi ro cực đoan.

Hạn chế của hướng tiếp cận này là kết quả phụ thuộc vào cách ước lượng phần đuôi phân phối và các tham số điều chỉnh mức phạt rủi ro. Nếu ước lượng không chính xác, chiến lược học tăng cường có thể đánh giá sai rủi ro extreme và đưa ra policy không tối ưu trong thực tế.

2.2.6. Sortino Ratio và Downside Risk.

Trong bài báo “*Performance Measurement in a Downside Risk Framework*”, Sortino và Price (1994) đề xuất Sortino Ratio, một chỉ số đánh giá hiệu quả đầu tư dựa trên downside risk, chỉ tập trung vào các biến động bất lợi thay vì toàn bộ biến động lợi nhuận. Phương pháp này giúp nhà đầu tư đánh giá rủi ro thực tế liên quan đến các khoản lỗ tiềm năng, phù hợp với bài toán giao dịch định lượng.

Trong thử nghiệm trên các danh mục đầu tư lịch sử, áp dụng Sortino Ratio giúp so sánh chiến lược một cách nhạy cảm với các biến động âm. Trong đề tài này, Sortino-PPO sử dụng ý tưởng downside risk để điều chỉnh reward, hướng mô hình học tăng cường đến việc giảm downside volatility của danh mục, đồng thời so sánh với baseline PPO trung lập rủi ro và chiến lược Buy & Hold. Kết quả cho thấy Sortino-PPO có khả

năng giảm các lỗ bất lợi trong giai đoạn thị trường giảm, cải thiện độ ổn định của danh mục mà vẫn giữ lợi nhuận tương đối.

Hạn chế của phương pháp là việc giảm downside volatility có thể khiến mô hình giao dịch thận trọng hơn, không tối ưu lợi nhuận tối đa trong mọi điều kiện thị trường, đặc biệt trong các giai đoạn tăng mạnh.

Từ các phương pháp trên có thể thấy, mỗi hướng tiếp cận có vai trò riêng trong quá trình xây dựng hệ thống. Buy & Hold cung cấp benchmark đơn giản để đối chiếu. PPO cung cấp baseline học tăng cường trung lập rủi ro. CVaR-PPO và Sortino-PPO bổ sung góc nhìn nhạy cảm rủi ro, phù hợp với mục tiêu phân tích sự đánh đổi giữa lợi nhuận, drawdown và volatility. Vì vậy, việc so sánh các phương pháp này trong cùng một môi trường backtest là phù hợp với mục tiêu của đề tài.

2.3 Phương pháp đề xuất giải quyết bài toán

Trong đề tài này, hướng giải quyết bài toán giao dịch định lượng được xây dựng dựa trên việc kết hợp các phương pháp học tăng cường và các chỉ số quản lý rủi ro. Cụ thể.

2.3.1. Chiến lược cơ sở (Buy & Hold)

Sử dụng làm chuẩn đối chiếu, đơn giản, không điều chỉnh theo trạng thái thị trường. Giúp so sánh hiệu quả của các mô hình học tăng cường.

2.3.2. Học tăng cường trực tiếp (Direct Reinforcement Learning - RRL)

Áp dụng thuật toán Recurrent Reinforcement Learning (RRL) để tối ưu trực tiếp chiến lược giao dịch từ dữ liệu lịch sử.

Mục tiêu là tối đa hóa lợi nhuận điều chỉnh rủi ro (differential Sharpe ratio) mà không cần dự báo giá trước.

Giới hạn: phụ thuộc vào dữ liệu huấn luyện, giả định chi phí giao dịch và khả năng tổng quát hóa sang các giai đoạn thị trường khác nhau.

2.3.3. Học tăng cường sâu cho quản lý danh mục (Deep Reinforcement Learning - FRL)

Áp dụng framework FRL (Jiang, Xu & Liang, 2017) để tối ưu phân bổ vốn giữa nhiều tài sản.

Sử dụng thông tin OHLCV và chỉ báo kỹ thuật để huấn luyện policy network.

Giới hạn: mô hình tập trung vào phân bổ danh mục nhiều tài sản, hạn chế khi áp dụng trực tiếp cho policy giao dịch đơn lẻ.

2.3.4. Proximal Policy Optimization (PPO)

Sử dụng PPO làm baseline trung lập rủi ro, tối ưu policy với Clipped Surrogate Objective để ổn định gradient.

Giới hạn: chỉ tối ưu expected reward, chưa kiểm soát tốt các rủi ro như drawdown, volatility hay tail risk.

2.3.5. Conditional Value at Risk (CVaR-PPO)

Kết hợp CVaR vào quá trình huấn luyện policy nhằm đưa yếu tố tail risk vào quyết định.

Giới hạn: kết quả phụ thuộc vào cách ước lượng phần đuôi phân phối và tham số điều chỉnh mức phạt rủi ro.


2.3.6. Sortino-PPO (Downside Risk):


Điều chỉnh reward dựa trên downside risk, giảm biến động bất lợi của danh mục.

Giới hạn: mô hình có thể giao dịch thận trọng hơn, không tối ưu lợi nhuận tối đa trong mọi giai đoạn thị trường.

CHƯƠNG 3. PHƯƠNG PHÁP ĐỀ XUẤT

3.1. Mô hình tổng quát





Hình 3.1: Quy trình tổng thể hệ thống RL cho giao dịch định lượng

3.1.1. Data Collection (Thu thập dữ liệu)

- Thu thập dữ liệu giá OHLCV, khối lượng giao dịch và các dữ liệu thị trường lịch sử (Historical Time Series).
- Dữ liệu này cung cấp thông tin đầu vào cho trạng thái của hệ thống, đảm bảo đại diện chính xác cho thị trường.

3.1.2. Data Preprocessing & Feature Extraction (Tiền xử lý và trích xuất đặc trưng)

- Làm sạch dữ liệu: xử lý missing value, loại bỏ outlier, chuẩn hóa/scale các feature.
- Trích xuất các chỉ số kỹ thuật như SMA, RSI, MACD, Volatility, cùng các đặc trưng lịch sử khác.
- Các feature này được tổ chức theo dạng vector/tensor để agent dễ dàng sử dụng.

3.1.3. Reinforcement Learning Environment (Môi trường học tăng cường)

- **State:** đại diện trạng thái thị trường dựa trên feature và quan sát lịch sử.
- **Action:** các quyết định giao dịch, ví dụ Buy / Sell / Hold hoặc Long / Short / Hold.
- **Reward:** giá trị tối ưu hóa liên quan đến lợi nhuận và rủi ro, gồm Profit, CVaR, Sortino, Drawdown.
- **Environment / Market Simulator:** mô phỏng phản hồi từ thị trường dựa trên hành động agent để cập nhật reward và trạng thái tiếp theo.

3.1.4. Policy Training (Huấn luyện policy)

- Huấn luyện agent bằng các phương pháp học tăng cường: PPO, CVaR-PPO, Sortino-PPO, sử dụng benchmark Buy & Hold.
- Mục tiêu huấn luyện: tối đa hóa reward liên quan trực tiếp đến lợi nhuận và rủi ro, đồng thời hạn chế drawdown và downside volatility.

3.1.5. Outputs / Evaluation (Kết quả và đánh giá)

- **Trading Policy:** chính sách giao dịch đã học.

- **Portfolio Allocation:** phân bổ danh mục đầu tư, ví dụ BTC 40%, ETH 30%, Cash 30%.
- **Expected Reward:** kỳ vọng lợi nhuận theo policy.
- **Backtest Performance:** đánh giá các chỉ số như Total Return, Sharpe Ratio, Max Drawdown, Volatility.

3.2 Xử lý dữ liệu và trích xuất đặc trưng

3.2.1. Cào dữ liệu


Hệ thống thu thập dữ liệu lịch sử từ Yahoo Finance thông qua thư viện yfinance. Dữ liệu được chuẩn hóa theo OHLCV (date, open, high, low, close, volume). Trong quá trình huấn luyện, dữ liệu hàng ngày của các tài sản như SPY, QQQ và GLD được tải từ 01/01/2018 đến 31/12/2024, trong đó SPY là tài sản chính. Khi triển khai realtime, hệ thống lấy khoảng một năm dữ liệu để đảm bảo đủ quan sát cho các chỉ số kỹ thuật.

Dữ liệu thô được tiền xử lý bao gồm: reset index, chuẩn hóa tên cột, lựa chọn các trường OHLCV, sắp xếp theo thứ tự thời gian và loại bỏ bản ghi trùng lặp. Các giá trị thiếu hoặc vô hạn được loại bỏ; các hàng có giá OHLC ≤ 0 cũng bị loại bỏ. Những hàng “warm-up” phát sinh do rolling indicator tạo ra được bỏ để tránh ảnh hưởng đến agent.

Outlier không được xử lý tự động; các biến động giá lớn hơn 50% trong một ngày chỉ được đánh dấu để kiểm tra chất lượng dữ liệu.

Các đặc trưng thị trường được chuẩn hóa theo thống kê thời gian huấn luyện lưu trong **norm_params.json**, đảm bảo cùng thang đo cho dữ liệu kiểm thử, xác thực và realtime. State của agent RL gồm 16 đặc trưng thị trường: giá đóng cửa, khối lượng, SMA (10/20/50), RSI, MACD và các biến thể, Bollinger Bands, ATR, return, log return, volume SMA; kết hợp với 3 biến danh mục: số dư tiền, giá trị cổ phiếu, tổng giá trị danh mục, tạo vector 19 chiều cho agent.

Các chỉ số kỹ thuật về xu hướng, động lượng, biến động, lợi nhuận và khối lượng được sử dụng làm input cho các policy PPO, CVaR-PPO và Sortino-PPO.



Hình 3.2: Quy trình thu thập và tiền xử lý dữ liệu thị trường

3.2.2 Trích xuất đặc trưng

Mục tiêu: Trích xuất tất cả các đặc trưng từ dữ liệu thị trường và biến danh mục để xây dựng state vector cho agent Reinforcement Learning. Các đặc trưng phải phản ánh đủ thông tin về giá, biến động, xu hướng, momentum, volume và tình trạng tài chính hiện tại của agent.

Nhóm đặc trưng thị trường:

- **Price & Return Features**

- + close: Giá đóng cửa (dùng làm giá lưu trữ chính)
- + returns: Lợi nhuận phần trăm hàng ngày

$$r_t = \frac{(close_t - close_{\{t-1\}})}{close_{\{t-1\}}}$$

- + log returns: Lợi nhuận log

$$\log_returns_t = \log\left(\frac{close_t}{close_{\{t-1\}}}\right)$$

– Trend & Momentum Indicators

- + SMA₁₀, SMA₂₀, SMA₅₀: SMA 10/20/50 ngày
- + RSI: RSI 14 ngày
- + MACD, MACD_{signal}, MACD_{diff}: Chỉ báo MACD

– Volatility Indicators

- + bb_{high}, bb_{mid}, bb_{low}: Bollinger Bands
- + atr: Average True Range

– Volume-based Features

- + volume: Khối lượng giao dịch hàng ngày
- + volume_{sma}: SMA 20 ngày của khối lượng
- + Mục đích: Bao quát đầy đủ thông tin về giá, biến động, xu hướng, momentum và khối lượng giao dịch để làm đầu vào cho state vector của agent.

Biến danh mục & Vector trạng thái cuối cùng

Mục tiêu: Kết hợp thông tin thị trường với các biến danh mục tài chính để agent quan sát đầy đủ trạng thái hiện tại, từ đó đưa ra quyết định giao dịch tối ưu.

– **Biến danh mục (Portfolio Variables)**

Các biến này thể hiện vị thế tài chính của agent tại từng bước thời gian:

- + **cash_ratio:** Tỷ lệ tiền mặt hiện có so với vốn ban đầu
- + **shares_value_ratio:** Tỷ lệ giá trị cổ phiếu hiện có so với vốn ban đầu
- + **portfolio_value_ratio:** Tỷ lệ tổng giá trị danh mục so với vốn ban đầu

Biến	Giá trị
Vốn ban đầu	10.000
Tiền mặt	6.000
Giá trị cổ phiếu	4.200
Tổng giá trị danh mục	10.200
cash_ratio	0,60
shares_value_ratio	0,42
portfolio_value_ratio	1,02

Bảng 3.1: Giá trị khởi tạo của danh mục đầu tư.

– **Vector trạng thái cuối cùng (Final State Vector)**

Vector trạng thái đầu vào của agent được tạo bằng cách kết hợp **16** đặc trưng thị trường đã chuẩn hóa với **3** biến danh mục:

- + Tổng chiều dài vector: **19**
- + Trình tự các giá trị trong vector:

[close, volume, sma₁₀, sma₂₀, sma₅₀, rsi, macd, macd_{signal}, macd_{diff}, bb_{high}, bb_{low}, bb_{mid}, atr, returns, log_{returns}, volume_{sma}, cash_ratio, shares_value_ratio, portfolio_value_ratio]

Đây là state vector mà agent Reinforcement Learning (PPO, CVaR-PPO, Sortino-PPO) sử dụng để ra quyết định giao dịch.

Ví dụ một bước thời gian (Example at One Timestep)

Mục tiêu: Minh họa chi tiết cách dữ liệu OHLCV được xử lý, tính toán các đặc trưng và tạo thành vector trạng thái để agent sử dụng.

Dữ liệu thị trường thô (OHLCV)

Ngày	Open	High	Low	Close	Volume
2024-01-02	472.16	473.67	470.49	472.65	123,623,700

Bảng 3.2: Dữ liệu thị trường thô (OHLCV)

Các đặc trưng tính toán (Feature Engineering)

Đặc trưng	Giá trị
close	472.65
volume	123,623,700
Sma ₁₀	470.82
Sma ₂₀	468.35
Sma ₅₀	455.90
rsi	63.40
macd	4.25
Macd _{signal}	3.80
Macd _{diff}	0.45

Bb_{high}	478.60
Bb_{mid}	468.35
Bb_{low}	458.10
atr	5.20
returns	0.0048
$\text{Log}_{returns}$	0.0048
Volume_{sma}	89,500,000

Bảng 3.3: Các đặt trưng tính toán

Các biến danh mục (Portfolio Variables)

Biến	Giá trị
cash_ratio	0.60
shares_value_ratio	0.42
portfolio_value_ratio	1.02

Bảng 3.4: Các biến danh mục

Vector trạng thái cuối cùng (Final State Vector)

Vector trạng thái agent sử dụng trong RL:

$st = [2.63, 0.84, 2.65, 2.66, 2.61, 0.58, 0.79, 0.72, 0.38, 2.65, 2.64, 2.66, 0.59, 0.31, 0.31, 0.16, 0.60, 0.42, 1.02]$

Trong đó 16 giá trị đầu là các đặc trưng thị trường chuẩn hóa, 3 giá trị cuối là các biến danh mục.

3.3 Môi trường giao dịch và mô hình hóa bài toán

Sau khi xây dựng vector trạng thái đầu vào, bài toán giao dịch được mô hình hóa dưới dạng một quá trình ra quyết định tuần tự. Ở mỗi thời điểm t , agent quan sát trạng thái hiện tại của thị trường và danh mục, sau đó lựa chọn một hành động giao dịch. Hành động này làm thay đổi số dư tiền mặt, số lượng cổ phiếu nắm giữ và giá trị danh mục ở thời điểm tiếp theo. Vì vậy, quyết định giao dịch tại một thời điểm không chỉ ảnh hưởng đến kết quả hiện tại mà còn ảnh hưởng đến trạng thái danh mục trong các bước sau.

Trong đề tài này, môi trường giao dịch được xây dựng dựa trên cơ chế của học tăng cường, trong đó agent tương tác trực tiếp với dữ liệu thị trường lịch sử. Mỗi bước giao dịch tương ứng với một ngày giao dịch trong dữ liệu. Tại mỗi bước, môi trường cung cấp trạng thái cho agent, nhận hành động từ agent, cập nhật danh mục và trả về phần thưởng tương ứng với sự thay đổi giá trị danh mục.

Bài toán có thể được mô tả theo các thành phần chính sau:

- **Trạng thái:** bao gồm các đặc trưng thị trường đã chuẩn hóa và các biến trạng thái danh mục.
- **Hành động:** là quyết định mua, bán hoặc nắm giữ tài sản.
- **Phần thưởng:** phản ánh mức thay đổi giá trị danh mục sau mỗi bước giao dịch.
- **Môi trường:** mô phỏng quá trình giao dịch, bao gồm cập nhật giá trị danh mục, chi phí giao dịch và trượt giá.

3.3.1 Không gian hành động

Trong hệ thống đề xuất, không gian hành động được thiết kế dưới dạng liên tục trong khoảng $[-1, 1]$. Giá trị hành động do mô hình sinh ra thể hiện mức độ can thiệp của agent vào danh mục hiện tại.

Nếu giá trị hành động lớn hơn 0.01, hệ thống diễn giải là tín hiệu BUY. Khi đó, agent sử dụng một tỷ lệ tiền mặt tương ứng với giá trị hành động để mua cổ phiếu. Nếu giá trị hành động nhỏ hơn -0.01, hệ thống diễn giải là tín hiệu SELL. Khi đó, agent bán

ra một tỷ lệ cổ phiếu đang nắm giữ tương ứng với độ lớn tuyệt đối của hành động. Nếu hành động nằm trong khoảng từ -0.01 đến 0.01, hệ thống xem đây là tín hiệu HOLD, tức agent không thực hiện giao dịch mới và giữ nguyên trạng thái danh mục.

Cách thiết kế hành động liên tục giúp mô hình không chỉ đưa ra quyết định mua hoặc bán đơn giản, mà còn điều chỉnh được mức độ giao dịch. Điều này phù hợp với bài toán giao dịch định lượng, vì trong thực tế chiến lược giao dịch cần quan tâm đến tỷ trọng phân bổ vốn thay vì chỉ quyết định mua toàn bộ hoặc bán toàn bộ.

3.3.2 Chi phí giao dịch và trượt giá

Để quá trình backtest gần với điều kiện giao dịch thực tế hơn, môi trường có xét đến chi phí giao dịch và trượt giá. Trong đề tài này, chi phí giao dịch được thiết lập là 0.1% cho mỗi lần mua hoặc bán. Ngoài ra, hệ thống sử dụng mức trượt giá 0.05% nhằm mô phỏng sự sai lệch giữa giá thị trường quan sát được và giá khớp lệnh thực tế.

Khi agent thực hiện lệnh mua, giá khớp lệnh được điều chỉnh cao hơn giá thị trường hiện tại do ảnh hưởng của trượt giá. Ngược lại, khi agent thực hiện lệnh bán, giá khớp lệnh được điều chỉnh thấp hơn giá thị trường hiện tại. Việc đưa chi phí giao dịch và trượt giá vào môi trường giúp hạn chế hiện tượng giao dịch quá mức, vì mỗi giao dịch đều làm giảm một phần giá trị danh mục.

3.3.3 Hàm phần thưởng

Hàm phần thưởng cơ sở được xác định dựa trên tỷ suất thay đổi giá trị danh mục sau mỗi bước giao dịch. Cụ thể, tại thời điểm t , phần thưởng được tính bằng chênh lệch giữa giá trị danh mục mới và giá trị danh mục trước đó, chia cho giá trị danh mục trước đó.

Công thức tổng quát như sau:

$$r_t = \frac{(V_t - V_{\{t-1\}})}{V_{\{t-1\}}}$$

Trong đó, V_t là giá trị danh mục tại thời điểm t và V_{t-1} là giá trị danh mục ở thời điểm trước đó. Cách thiết kế reward này giúp agent học cách tối đa hóa mức tăng trưởng của danh mục theo thời gian.

Tuy nhiên, nếu chỉ sử dụng phần thưởng dựa trên lợi nhuận, mô hình có thể ưu tiên các hành động rủi ro cao để tăng lợi nhuận ngắn hạn. Vì vậy, bên cạnh mô hình PPO cơ sở, đề tài triển khai thêm các biến thể nhạy cảm rủi ro như CVaR-PPO và Sortino-PPO nhằm đưa yếu tố rủi ro vào quá trình huấn luyện.

3.4 Các mô hình học tăng cường được sử dụng

Sau khi xây dựng môi trường giao dịch, đề tài sử dụng các mô hình học tăng cường để học chính sách giao dịch từ dữ liệu lịch sử. Các mô hình được triển khai gồm PPO, CVaR-PPO và Sortino-PPO. Ngoài ra, chiến lược Buy & Hold được sử dụng làm phương pháp đối chứng để so sánh hiệu quả của các mô hình học tăng cường với một chiến lược đầu tư thụ động.

Trong hệ thống đề xuất, PPO, CVaR-PPO và Sortino-PPO sử dụng chung kiến trúc Actor-Critic. Có thể hiểu Actor là bộ sinh hành động, còn Critic là bộ đánh giá trạng thái. Actor nhận vector trạng thái đầu vào và sinh ra hành động giao dịch trong khoảng $[-1, 1]$. Hành động này sau đó được diễn giải thành tín hiệu mua, bán hoặc nắm giữ. Trong khi đó, Critic ước lượng giá trị của trạng thái hiện tại để hỗ trợ quá trình cập nhật chính sách trong huấn luyện.

Việc sử dụng chung kiến trúc Actor-Critic giúp các mô hình có cùng cấu trúc đầu vào và đầu ra, từ đó đảm bảo việc so sánh giữa PPO, CVaR-PPO và Sortino-PPO được thực hiện trên cùng một nền tảng. Điểm khác biệt chính giữa các mô hình nằm ở cách đưa yếu tố rủi ro vào quá trình tối ưu. PPO đóng vai trò mô hình cơ sở trung lập rủi ro, CVaR-PPO tập trung vào rủi ro đuôi, còn Sortino-PPO tập trung vào biến động bất lợi của lợi nhuận.

Mô hình	Vai trò trong đề tài	Yếu tố tối ưu chính	Đặc điểm
Buy & Hold	Benchmark đối chứng	Lợi nhuận thụ động theo thị trường	Mua ở đầu kỳ và nắm giữ đến cuối kỳ
PPO	Mô hình cơ sở	Lợi nhuận kỳ vọng	Học chính sách giao dịch trung lập rủi ro
CVaR-PPO	Mô hình nhạy cảm rủi ro đuôi	Hạn chế các trường hợp thua lỗ xấu nhất	Thêm penalty dựa trên nhóm return bất lợi
Sortino-PPO	Mô hình nhạy cảm downside risk	Giảm biến động bất lợi	Điều chỉnh reward dựa trên downside deviation

Bảng 3.5: Tóm tắt vai trò của từng mô hình trong hệ thống đề xuất.

3.5 Quy trình huấn luyện và suy luận

Sau khi xây dựng môi trường giao dịch và xác định các mô hình sử dụng, hệ thống tiến hành huấn luyện agent trên dữ liệu lịch sử. Quy trình huấn luyện được thực hiện theo thứ tự thời gian của dữ liệu, không xáo trộn ngẫu nhiên như các bài toán học có giám sát thông thường. Cách làm này phù hợp với dữ liệu tài chính, vì thông tin ở tương lai không được phép xuất hiện trong quá trình học ở quá khứ.

Trong quá trình huấn luyện, tại mỗi episode, môi trường giao dịch được khởi tạo lại với số vốn ban đầu. Agent bắt đầu từ ngày giao dịch đầu tiên của tập huấn luyện và lần lượt đi qua từng ngày trong dữ liệu. Ở mỗi bước, agent nhận vector trạng thái hiện tại, sinh ra hành động giao dịch, sau đó môi trường cập nhật số dư tiền mặt, số lượng cổ phiếu nắm giữ và giá trị danh mục. Dựa trên sự thay đổi giá trị danh mục, môi trường trả về reward để agent học cách cải thiện chính sách giao dịch.

Mô hình	Cách huấn luyện	Mục đích
PPO	Cập nhật chính sách dựa trên reward cơ sở là tỷ suất thay đổi giá trị danh mục	Làm mô hình cơ sở trung lập rủi ro

CVaR-PPO	Bổ sung thành phần phạt, tập trung vào nhóm lợi nhuận xấu nhất trong batch	Hạn chế rủi ro đuôi và các tình huống thua lỗ lớn
Sortino-PPO	Điều chỉnh reward bằng cách phạt biến động bất lợi của lợi nhuận	Giảm downside risk và giúp danh mục ổn định hơn

Bảng 3.6: Sự khác biệt trong quá trình huấn luyện giữa các mô hình

Từ bảng trên có thể thấy, ba mô hình được huấn luyện trong cùng một môi trường nhưng khác nhau ở cách đưa yếu tố rủi ro vào quá trình tối ưu.

Ở giai đoạn suy luận, hệ thống tải lại trọng số mô hình đã huấn luyện và các tham số chuẩn hóa đặc trưng được lưu từ tập train. Dữ liệu đầu vào mới được xử lý theo cùng quy trình với dữ liệu huấn luyện, sau đó được chuẩn hóa bằng mean và standard deviation của tập train.

Mô hình nhận vector trạng thái đã chuẩn hóa và sinh ra hành động giao dịch. Hành động này được chuyển đổi thành tín hiệu BUY, SELL hoặc HOLD để phục vụ chức năng dự đoán tín hiệu, backtest và so sánh mô hình trên giao diện demo.

CHƯƠNG 4. THỰC NGHIỆM

4.1 Dữ liệu

Dữ liệu thực nghiệm được thu thập từ Yahoo Finance thông qua thư viện yfinance. Đây là nguồn dữ liệu tài chính phổ biến, cung cấp dữ liệu giá lịch sử của nhiều tài sản theo định dạng OHLCV, bao gồm giá mở cửa, giá cao nhất, giá thấp nhất, giá đóng cửa và khối lượng giao dịch.

Trong đề tài, dữ liệu được sử dụng gồm ba tài sản đại diện cho các nhóm thị trường khác nhau: SPY, QQQ và GLD. SPY là ETF mô phỏng chỉ số S&P 500, được sử dụng làm tài sản chính trong quá trình huấn luyện. QQQ là ETF đại diện cho nhóm cổ phiếu công nghệ thuộc Nasdaq-100, còn GLD là ETF đại diện cho vàng. Việc sử dụng thêm QQQ và GLD giúp kiểm tra khả năng tổng quát hóa của mô hình trên các tài sản khác nhau.

Dữ liệu được lấy theo tần suất ngày, trong giai đoạn từ ngày 01/01/2018 đến ngày 31/12/2024. Sau khi thu thập và xử lý các chỉ báo kỹ thuật, mỗi tài sản còn 1711 dòng dữ liệu hợp lệ. Dữ liệu được chia theo thứ tự thời gian thay vì chia ngẫu nhiên, nhằm phù hợp với đặc điểm của chuỗi thời gian tài chính và tránh rò rỉ thông tin từ tương lai.

Cụ thể, tập huấn luyện gồm dữ liệu giai đoạn 2018–2021, tập validation gồm dữ liệu năm 2022 và tập test gồm dữ liệu giai đoạn 2023–2024. Cách chia này giúp đánh giá mô hình trên các chế độ thị trường khác nhau: giai đoạn huấn luyện có cả xu hướng tăng và cú sụt giảm do COVID-19, tập validation là giai đoạn thị trường giảm năm 2022, còn tập test là giai đoạn thị trường phục hồi và tăng trưởng.

Tập dữ liệu	Giai đoạn	Vai trò	Đặc điểm
Train	2018–2021	Huấn luyện mô hình	Có cả xu hướng tăng và giai đoạn COVID-19
Validation	2022	Kiểm tra trong quá trình đánh giá	Giai đoạn thị trường giảm
Test	2023–2024	Đánh giá kết quả cuối cùng	Giai đoạn phục hồi và tăng trưởng

Bảng 4.1: Phân chia tập dữ liệu và vai trò từng giai đoạn

Tài sản	Ý nghĩa	Vai trò trong thực nghiệm
SPY	ETF mô phỏng S&P 500	Tài sản chính dùng để huấn luyện và kiểm thử
QQQ	ETF mô phỏng Nasdaq-100	Dùng để đánh giá khả năng tổng quát hóa
GLD	ETF đại diện cho vàng	Dùng để đánh giá khả năng tổng quát hóa trên tài sản khác nhóm

Bảng 4.2: Vai trò và ý nghĩa các tài sản trong thực nghiệm

4.2 Xử lý dữ liệu

Dữ liệu tài chính cần được tiền xử lý trước khi đưa vào mô hình vì dữ liệu chuỗi thời gian có thể chứa giá trị thiếu, giá trị không hợp lệ hoặc phát sinh NaN sau quá trình tính toán chỉ báo kỹ thuật. Ngoài ra, các đặc trưng như giá, khối lượng giao dịch và chỉ báo kỹ thuật có thang đo khác nhau, nếu không chuẩn hóa có thể làm quá trình huấn luyện mô hình kém ổn định.

Quy trình xử lý dữ liệu trong đề tài gồm các bước chính. Đầu tiên, dữ liệu OHLCV được sắp xếp theo thời gian và loại bỏ các dòng bị trùng hoặc có giá trị không hợp lệ. Sau đó, hệ thống tính toán các chỉ báo kỹ thuật như SMA, RSI, MACD, Bollinger Bands, ATR, returns, log returns và volume SMA. Các dòng phát sinh giá trị NaN trong giai đoạn khởi động của chỉ báo được loại bỏ để đảm bảo dữ liệu đầu vào đầy đủ.

Sau khi tạo đặc trưng, dữ liệu được chia thành tập train, validation và test theo thứ tự thời gian. Các đặc trưng thị trường được chuẩn hóa bằng phương pháp Z-score dựa trên mean và standard deviation của tập train. Các tham số chuẩn hóa này được lưu lại để sử dụng thống nhất trong giai đoạn đánh giá và demo. Cách xử lý này giúp hạn chế rò rỉ dữ liệu, vì thông tin từ tập validation hoặc test không được sử dụng để tính tham số chuẩn hóa.

Bước xử lý	Mục đích
Sắp xếp dữ liệu theo thời gian	Đảm bảo đúng thứ tự chuỗi thời gian
Loại bỏ dòng trùng, giá trị thiếu hoặc không hợp lệ	Làm sạch dữ liệu đầu vào
Tính toán chỉ báo kỹ thuật	Tạo đặc trưng cho trạng thái thị trường
Loại bỏ NaN sau indicator warm-up	Đảm bảo mỗi mẫu có đầy đủ đặc trưng
Chuẩn hóa bằng tham số từ tập train	Giảm khác biệt thang đo và hạn chế data leakage

Bảng 4.3: Các bước xử lý dữ liệu và mục đích

4.3 Công nghệ sử dụng

- Ngôn ngữ lập trình: Python.
- Thu thập dữ liệu: yfinance.
- Xử lý dữ liệu: Pandas, NumPy.

- Tính toán chi báo kỹ thuật: ta.
- Huấn luyện mô hình học tăng cường: PyTorch, Gymnasium.
- Trực quan hóa và demo: Matplotlib, Plotly, Django.

4.4 Cách đánh giá

Trong bài toán giao dịch định lượng, việc đánh giá mô hình không chỉ dựa trên lợi nhuận cuối kỳ mà còn cần xem xét mức độ rủi ro đi kèm. Một chiến lược có lợi nhuận cao nhưng biến động lớn hoặc mức sụt giảm sâu vẫn có thể không phù hợp trong thực tế. Vì vậy, đề tài sử dụng nhiều chỉ số đánh giá nhằm phản ánh đồng thời hiệu quả sinh lời, mức độ ổn định và rủi ro của từng chiến lược.

Giá trị danh mục tại thời điểm t được ký hiệu là V_t , giá trị danh mục ban đầu là V_0 . Tỷ suất lợi nhuận tại mỗi bước giao dịch được tính như sau:

$$r_t = \frac{(V_t - V_{\{t-1\}})}{V_{\{t-1\}}}$$

Từ chuỗi giá trị danh mục và chuỗi lợi nhuận theo ngày, hệ thống tính toán các độ đo đánh giá chính như sau:

Độ đo	Công thức / cách tính	Ý nghĩa
Total Return	$\frac{(V_T - V_0)}{V_0}$	Tỷ suất sinh lời tổng của chiến lược trong toàn bộ giai đoạn đánh giá
Annualized Return	$(1 + TotalReturn)^{(252 / N)} - 1$	Tỷ suất sinh lời quy đổi theo năm, với N là số ngày giao dịch
Volatility	$std(r_t) * \sqrt{(252)}$	Mức biến động lợi nhuận quy năm
Sharpe Ratio	$\frac{Annualized Return}{Volatility}$	Lợi nhuận đạt được trên mỗi đơn vị rủi ro tổng thể

Sortino Ratio	$\frac{\text{Annualized Return}}{\text{Downside Deviation}}$	Lợi nhuận đạt được trên mỗi đơn vị rủi ro bất lợi
Max Drawdown	$\min\left(\frac{V_t - \text{Peak}_t}{\text{Peak}_t}\right)$	Mức sụt giảm lớn nhất từ đỉnh danh mục xuống đáy
Calmar Ratio	$\frac{\text{Annualized Return}}{\text{MaxDrawdown}}$	Max Drawdown
VaR-95	Phân vị 5% của chuỗi lợi nhuận ngày	Mức lỗ ngưỡng trong 5% trường hợp xấu nhất
CVaR-95	Trung bình các lợi nhuận nhỏ hơn hoặc bằng VaR-95	Mức lỗ trung bình trong nhóm tình huống xấu nhất
Win Rate	Số ngày có lợi nhuận dương / tổng số ngày	Tỷ lệ ngày giao dịch có lợi nhuận dương

Bảng 4.4: Các chỉ số đo lường hiệu quả chiến lược giao dịch

Trong các chỉ số trên, Total Return cho biết mức tăng trưởng cuối cùng của danh mục, nhưng chưa phản ánh đầy đủ rủi ro. Sharpe Ratio và Sortino Ratio được sử dụng để đánh giá lợi nhuận có điều chỉnh theo rủi ro. Trong đó, Sortino Ratio phù hợp với bài toán giao dịch hơn trong nhiều trường hợp vì chỉ tập trung vào biến động bất lợi. Max Drawdown thể hiện mức sụt giảm sâu nhất của danh mục, đây là chỉ số quan trọng để đánh giá mức độ chịu rủi ro của chiến lược. CVaR-95 được sử dụng để đo lường rủi ro đuôi, tức mức tổn thất trung bình trong nhóm tình huống xấu nhất.

Trong thực nghiệm, các mô hình PPO, CVaR-PPO, Sortino-PPO và chiến lược Buy & Hold được đánh giá trên cùng một tập dữ liệu test và cùng một bộ chỉ số. Cách đánh giá này giúp so sánh công bằng giữa chiến lược học tăng cường trung lập rủi ro, chiến lược học tăng cường nhạy cảm rủi ro và chiến lược đầu tư thụ động.

4.5 Kết quả đạt được

Phần này trình bày cấu hình thực nghiệm, kết quả huấn luyện và kết quả đánh giá các chiến lược trên tập test. Các mô hình được so sánh gồm PPO, CVaR-PPO, Sortino-PPO và chiến lược Buy & Hold.

4.5.1 Thiết lập tham số thực nghiệm

Nhóm	Tham số	Giá trị
Dữ liệu	Tài sản	SPY, QQQ, GLD
Dữ liệu	Tài sản huấn luyện chính	SPY
Dữ liệu	Giai đoạn dữ liệu	2018–2024
Dữ liệu	Train / Validation / Test	2018–2021 / 2022 / 2023–2024
Môi trường	Vốn ban đầu	10,000 USD
Môi trường	Transaction cost	0.1%
Môi trường	Slippage	0.05%
Mạng neural	Hidden dimension	256
PPO	Learning rate	2e-4
PPO	Gamma	0.99
PPO	PPO epsilon	0.2
PPO	PPO epochs	8
CVaR-PPO	CVaR alpha	0.15
CVaR-PPO	CVaR lambda	0.15, giảm dần đến 0.08
CVaR-PPO	L2 regularization	1e-5
Sortino-PPO	Sortino lambda	0.2
Huấn luyện	Số episode	300
Huấn luyện	Update interval	256 steps
Thiết bị	Device	CUDA

Bảng 4.5: Tham số chính được sử dụng trong quá trình huấn luyện và đánh giá mô hình.

Các tham số trên được giữ thống nhất giữa các mô hình để đảm bảo quá trình so sánh công bằng. Sự khác biệt chính giữa PPO, CVaR-PPO và Sortino-PPO nằm ở cách từng mô hình đưa yếu tố rủi ro vào quá trình tối ưu chính sách giao dịch.

4.5.2 Kết quả trong quá trình huấn luyện

Kết quả ghi nhận ở cuối quá trình huấn luyện 300 episodes. Các giá trị này phản ánh xu hướng học của mô hình trên tập train, chưa được dùng làm kết luận cuối cùng về hiệu quả chiến lược.

Mô hình	Avg Reward ở episode 300	Avg Portfolio ở episode 300	Final portfolio sau train
PPO	+0.3971	14,535.70 USD	12,434.05 USD
CVaR-PPO	+0.3410	13,652.02 USD	14,089.07 USD
Sortino-PPO	+0.3488	13,894.47 USD	13,060.67 USD

Bảng 4.6: Kết quả ghi nhận cuối quá trình huấn luyện

Kết quả cho thấy cả ba mô hình đều đạt giá trị danh mục cuối quá trình huấn luyện cao hơn vốn ban đầu 10,000 USD. PPO có Avg Reward và Avg Portfolio ở episode 300 cao nhất, trong khi CVaR-PPO có Final portfolio sau train cao nhất. Tuy nhiên, kết quả trên tập train chỉ phản ánh khả năng học của mô hình trong môi trường huấn luyện. Để đánh giá hiệu quả thực nghiệm, cần xem xét kết quả trên tập test và các chỉ số rủi ro/lợi nhuận ở các mục tiếp theo.

4.5.3 Kết quả đánh giá trên tập test

Sau khi huấn luyện, các mô hình được đánh giá trên tập test giai đoạn 2023–2024. Ngoài SPY là tài sản chính dùng để huấn luyện, đề tài còn đánh giá thêm trên QQQ và GLD để kiểm tra khả năng tổng quát hóa của mô hình trên các tài sản khác. Các mô hình PPO, CVaR-PPO và Sortino-PPO được so sánh với chiến lược Buy & Hold trên cùng các chỉ số Total Return, Sharpe Ratio, Max Drawdown và CVaR-95.

Tài sản	Mô hình	Total Return	Sharpe Ratio	Max Drawdown	CVaR-95
SPY	PPO	+12.32%	0.920	-5.02%	-1.005%
SPY	CVaR-PPO	+21.80%	1.303	-6.55%	-1.169%
SPY	Sortino-PPO	+17.20%	1.110	-6.12%	-1.078%
SPY	Buy & Hold	+58.82%	1.884	-9.97%	-1.742%
QQQ	PPO	+39.64%	1.835	-8.18%	-1.285%
QQQ	CVaR-PPO	+46.14%	1.662	-8.11%	-1.637%
QQQ	Sortino-PPO	+41.24%	1.595	-7.57%	-1.572%
QQQ	Buy & Hold	+97.47%	2.004	-13.56%	-2.376%
GLD	PPO	+16.03%	1.002	-9.38%	-1.079%
GLD	CVaR-PPO	+13.04%	0.687	-9.26%	-1.491%
GLD	Sortino-PPO	+12.28%	0.746	-9.01%	-1.231%
GLD	Buy & Hold	+40.67%	1.281	-11.35%	-1.980%

Bảng 4.7: Kết quả đánh giá các mô hình trên tập test 2023–2024

Kết quả cho thấy Buy & Hold đạt Total Return cao nhất trên cả ba tài sản. Điều này phù hợp với bối cảnh tập test 2023–2024 là giai đoạn thị trường phục hồi và tăng trưởng, trong đó chiến lược nắm giữ thụ động thường có lợi thế về lợi nhuận tuyệt đối.

Tuy nhiên, các mô hình học tăng cường vẫn thể hiện ý nghĩa trong việc phân tích sự đánh đổi giữa lợi nhuận và rủi ro. Trên SPY, CVaR-PPO đạt Total Return 21.80% và


Sharpe Ratio 1.303, cao nhất trong nhóm mô hình học tăng cường. PPO có Max Drawdown thấp nhất trong nhóm mô hình học tăng cường trên SPY với -5.02%, cho thấy mức sụt giảm danh mục được kiểm soát tốt hơn so với Buy & Hold.

Trên QQQ, các mô hình học tăng cường đều đạt lợi nhuận dương, trong đó CVaR-PPO đạt Total Return cao nhất trong nhóm RL với 46.14%. Tuy nhiên, Buy & Hold vẫn vượt trội về lợi nhuận do QQQ tăng mạnh trong giai đoạn test. Trên GLD, PPO đạt kết quả tốt nhất trong nhóm RL với Total Return 16.03% và Sharpe Ratio 1.002, trong khi Buy & Hold vẫn đạt lợi nhuận cao nhất.

Nhìn chung, Buy & Hold phù hợp với giai đoạn thị trường tăng mạnh, nhưng đi kèm Max Drawdown và CVaR-95 lớn hơn so với nhiều mô hình học tăng cường. Các mô hình PPO, CVaR-PPO và Sortino-PPO không vượt Buy & Hold về lợi nhuận tuyệt đối trong giai đoạn test, nhưng giúp quan sát rõ hơn cách các chiến lược khác nhau kiểm soát drawdown và rủi ro đuôi.

4.5.4 So sánh với phương pháp đối chứng


Để đánh giá hiệu quả các mô hình học tăng cường, chúng được so sánh với chiến lược Buy & Hold. So sánh được thực hiện dựa trên Total Return và Sharpe Ratio trên tập test 2023–2024.



Hình 4.1: Đường giá trị danh mục của các chiến lược trên tập test 2023–2024.

- **Buy & Hold** (màu cam) đạt lợi nhuận tuyệt đối cao nhất, phản ánh thị trường trong giai đoạn test tăng trưởng mạnh. Tuy nhiên, đường vốn dao động lớn, thể hiện biến động/rủi ro cao.
- **PPO, CVaR-PPO, Sortino-PPO** (màu xanh, đỏ, lục) tăng chậm hơn nhưng ổn định hơn, ít biến động so với Buy & Hold, thể hiện khả năng kiểm soát rủi ro hiệu quả của các mô hình học tăng cường.
- CVaR-PPO và Sortino-PPO giữ đường vốn cao hơn PPO trong nhiều thời điểm, nhờ cơ chế nhạy cảm rủi ro, giảm tác động của các cú giảm mạnh.
- Tất cả mô hình đều vượt vốn ban đầu 10,000 USD, chứng tỏ agent đã học chính sách cải thiện giá trị danh mục trong môi trường test.

Kết luận: Buy & Hold sinh lợi cao nhất nhưng đi kèm biến động lớn; các mô hình RL kiểm soát rủi ro tốt hơn, cung cấp giải pháp cân bằng giữa sinh lời và ổn định.




Hình 3.2: So sánh các chỉ số đánh giá chính của các mô hình học tăng cường và chiến lược Buy & Hold trên tập test 2023–2024.

- **Total Return:** Buy & Hold dẫn đầu trên tất cả các tài sản, đạt lợi nhuận tuyệt đối cao nhất. Trong nhóm RL, CVaR-PPO có Total Return cao nhất, theo sau là Sortino-PPO và PPO.
- **Sharpe Ratio:** Các mô hình RL có Sharpe Ratio cao hơn PPO trên SPY và GLD, cho thấy **khả năng sinh lời trên mỗi đơn vị rủi ro tốt hơn** so với PPO. Buy & Hold có Sharpe cao nhất trên SPY và QQQ, nhưng đi kèm Max Drawdown lớn.
- **Sortino Ratio:** Tương tự Sharpe Ratio, các mô hình nhạy cảm rủi ro (CVaR-PPO, Sortino-PPO) thể hiện tốt hơn so với PPO, tập trung vào kiểm soát biến động bất lợi.
- **Max Drawdown & CVaR-95:** Buy & Hold chịu mức giảm sâu hơn, trong khi các mô hình RL hạn chế rủi ro đuôi và giảm sụt giảm lớn nhờ cơ chế nhạy cảm rủi ro.

- **Calmar Ratio:** Cho thấy trade-off giữa lợi nhuận và mức sụt giảm lớn nhất; các mô hình RL có Calmar thấp hơn Buy & Hold nhưng ổn định hơn về rủi ro.

Kết luận: Biểu đồ cho phép trực quan so sánh các chiến lược về lợi nhuận và rủi ro đồng thời. Buy & Hold tối ưu về lợi nhuận tuyệt đối, nhưng các mô hình RL cân bằng hơn giữa sinh lời và ổn định danh mục, phù hợp với mục tiêu quản lý rủi ro.




Hình 4.3: Drawdown theo phần trăm của các chiến lược trên tập test 2023–2024

- **Buy & Hold** (màu cam) chịu mức sụt giảm sâu nhất, với Max Drawdown - 9.97%, phản ánh rủi ro cao khi thị trường có biến động lớn.
- **PPO, CVaR-PPO, Sortino-PPO** (màu xanh, đỏ, lục) hạn chế được mức giảm so với Buy & Hold, cho thấy **khả năng kiểm soát rủi ro** hiệu quả nhờ cơ chế học tăng cường.
- CVaR-PPO có Max Drawdown sâu nhất trong nhóm RL (-8.31%), do mô hình nhạy cảm rủi ro đuôi cân bằng giữa sinh lời và biến động. PPO có Max

Drawdown thấp nhất (-5.90%), thể hiện mức giảm danh mục nhỏ nhất trong quá trình test.

- Sortino-PPO giữ mức giảm trung bình thấp hơn CVaR-PPO (-7.23%), phản ánh khả năng cân bằng giữa kiểm soát downside risk và sinh lời.

Kết luận: Biểu đồ trực quan cho thấy các mô hình học tăng cường kiểm soát drawdown tốt hơn Buy & Hold, cung cấp góc nhìn rõ ràng về **trade-off giữa lợi nhuận và rủi ro**.



Hình 4.4: Phân phối lợi nhuận hàng ngày của các mô hình RL và Buy & Hold

- **Buy & Hold** (màu cam) có độ biến động lớn nhất, phân phối rộng, với VaR-95 = -1.742% và CVaR-95 = -1.742%, phản ánh rủi ro đuôi cao và khả năng chịu cú sốc thị trường kém.
- **PPO, CVaR-PPO, Sortino-PPO** có phân phối hẹp hơn, tập trung quanh giá trị dương nhỏ, thể hiện biến động thấp hơn và kiểm soát rủi ro tốt hơn.

- CVaR-PPO có $\text{VaR-95} = -1.3178\%$, $\text{CVaR-95} = -1.3178\%$, cho thấy mô hình nhạy cảm rủi ro đuôi hạn chế các cú giảm xấu nhất hiệu quả hơn PPO và Sortino-PPO.
- Sortino-PPO cân bằng giữa lợi nhuận trung bình ($\text{Mean} = 0.0298\%$) và kiểm soát downside risk ($\text{CVaR-95} = -1.2552\%$).
- PPO có độ lệch chuẩn thấp nhất ($\text{Std} = 0.4371\%$), thể hiện mức biến động thấp nhất trong nhóm RL.

Kết luận: Biểu đồ trực quan cho thấy các mô hình học tăng cường kiểm soát **biến động và rủi ro đuôi** tốt hơn Buy & Hold, đồng thời duy trì lợi nhuận hàng ngày dương ổn định. Đây là minh chứng bổ sung cho phân tích trade-off lợi nhuận – rủi ro giữa các chiến lược.

Giải thích kết quả và nguyên nhân khác biệt giữa các phương pháp:

- **Buy & Hold đạt Total Return cao nhất** vì giai đoạn test 2023–2024 là thị trường phục hồi và tăng trưởng mạnh. Chiến lược thụ động nắm giữ toàn bộ danh mục suốt thời gian này nên hưởng trọn đà tăng giá.
- **Các mô hình RL (PPO, CVaR-PPO, Sortino-PPO) có lợi nhuận thấp hơn Buy & Hold** do mục tiêu tối ưu của chúng không chỉ là lợi nhuận tuyệt đối, mà còn cân nhắc **rủi ro, drawdown và rủi ro đuôi**.
- **CVaR-PPO và Sortino-PPO hạn chế rủi ro tốt hơn PPO** nhờ cơ chế nhạy cảm rủi ro:
 - + CVaR-PPO giảm ảnh hưởng các cú sụt giảm lớn thông qua penalty trên nhóm return xấu nhất.
 - + Sortino-PPO điều chỉnh reward dựa trên biến động bất lợi (downside deviation).

- **PPO tăng ổn định nhưng không nhạy cảm rủi ro** → có lợi nhuận trung bình thấp hơn CVaR-PPO và Sortino-PPO, nhưng Max Drawdown nhỏ nhất trong nhóm RL, phù hợp với môi trường cân cân bằng sinh lời và rủi ro.
- **Biến động thị trường, cơ chế tối ưu và reward function** là nguyên nhân chính dẫn đến khác biệt kết quả:
 - + Buy & Hold: tối ưu hoàn toàn lợi nhuận, không kiểm soát rủi ro → Max Drawdown lớn.
 - + PPO: tối ưu reward bình thường, không nhạy rủi ro → biến động vừa phải, sinh lời vừa phải.
 - + CVaR-PPO / Sortino-PPO: reward nhạy rủi ro → kiểm soát drawdown và tail-risk tốt hơn, nhưng Total Return bị giới hạn.

Kết luận tổng hợp:

Các khác biệt giữa các chiến lược đến từ **mục tiêu tối ưu, cơ chế nhạy cảm rủi ro và đặc tính reward**, dẫn đến **trade-off rõ ràng giữa lợi nhuận tuyệt đối và kiểm soát rủi ro**. Biểu đồ, bảng và drawdown minh họa trực quan điều này, giúp so sánh hiệu quả giữa các chiến lược học tăng cường và Buy & Hold.

4.5.5. So sánh kết quả với các nghiên cứu khác

Nghiên cứu	Phương pháp	Tài sản	Giai đoạn test	Total Return	Sharpe Ratio	Max Drawdown	Kiểm soát rủi ro
Đề tài này	PPO	SPY	2023–2024	+12,32%	0,920	-5,02%	Trung lập
Đề tài này	CVaR-PPO	SPY	2023–2024	+21,80%	1,303	-6,55%	Rủi ro đuôi (CVaR)
Đề tài này	Sortino-PPO	SPY	2023–2024	+17,20%	1,110	-6,12%	Downside risk
Đề tài này	Buy & Hold	SPY	2023–2024	+58,82%	1,884	-9,97%	Không

FinRL (Liu et al., 2020)	PPO (FinRL)	DJI A	2020– 2021	+28,50%	1,420	-8,30%	Trung lập
FinRL (Liu et al., 2020)	A2C (FinRL)	DJI A	2020– 2021	+25,10%	1,280	-9,10%	Trung lập
DeepTrader (Wang et al., 2021)	DRL + Market Condition	S&P 500	2019– 2020	+18,60%	1,150	-7,80%	Market- aware
CVaR- DRL (Cui et al., 2022)	CVaR- DRL	BT C/E TH	2021– 2022	+15,40%	0,890	-12,50%	CVaR penalty
DRL Ensemble (Yang et al., 2020)	Ensemble (PPO+A2 C+DDPG)	DJI A	2019– 2020	+32,70%	1,560	-7,20%	Ensembl e voting
MetaTrader (Niu et al., 2022)	Meta-RL Diverse Policy	S&P 500	2020– 2021	+22,30%	1,180	-8,90%	Meta- learning
Adaptive Portfolio (Almahdi & Yang, 2017)	RRL + MDD	S&P 500	2010– 2016	+14,20%	0,950	-6,80%	Max Drawdo wn
Cost- Sensitive (Zhang et al., 2020)	Cost- Sensitive DRL	CSI 300	2018– 2019	+19,80%	1,050	-10,20%	Transacti on cost

Bảng 4.8: So sánh kết quả thực nghiệm giữa hệ thống đề xuất và các nghiên cứu liên quan (trên tài sản SPY hoặc S&P 500, giai đoạn test tương đương)


Phương pháp	Ưu điểm	Nhược điểm
PPO (Đề tài)	Max Drawdown thấp nhất (-5,02%) Ổn định, dễ triển khai	Total Return thấp nhất trong nhóm RL Không nhạy cảm rủi ro

CVaR-PPO (Đề tài)	Sharpe cao nhất nhóm RL (1,303) Kiểm soát rủi ro đuôi tốt	Total Return thấp hơn Buy & Hold Cần điều chỉnh λ CVaR
Sortino-PPO (Đề tài)	Cân bằng downside risk Giảm biến động bất lợi	Lợi nhuận thấp hơn CVaR-PPO Thận trọng trong thị trường tăng
FinRL PPO (Liu et al.)	Thư viện mã nguồn mở Hỗ trợ nhiều thuật toán	Không tích hợp risk- sensitive Phụ thuộc vào giai đoạn test
DeepTrader (Wang et al.)	Nhúng market condition Cân bằng risk-return	Kiến trúc phức tạp Khó tái tạo kết quả
DRL Ensemble (Yang et al.)	Sharpe cao (1,560) Giảm phương sai bằng voting	Cần train nhiều mô hình Chi phí tính toán cao
CVaR-DRL Crypto (Cui et al.)	Áp dụng CVaR cho crypto Kiểm soát tail risk	Max Drawdown cao (- 12,50%) Chỉ thử nghiệm trên crypto
MetaTrader (Niu et al.)	Meta-learning đa chiến lược Linh hoạt	Phức tạp triển khai Cần nhiều dữ liệu huấn luyện

Bảng 4.9: Tổng hợp ưu điểm và nhược điểm của từng phương pháp


4.6 Giao diện Web Demo

Hệ thống cung cấp một giao diện web trực quan để người dùng quan sát hoạt động giao dịch của các mô hình RL (PPO, CVaR-PPO, Sortino-PPO) trên dữ liệu thị trường thực. Web demo minh họa các hành động mua/bán/nắm giữ, giá trị danh mục theo thời gian và các chỉ báo rủi ro.



Hình 4.5: Giao diện tổng quan của Web App

- Hiển thị danh mục đầu tư hiện tại, số dư tiền mặt và giá trị cổ phiếu đang nắm giữ.
- Biểu đồ lịch sử giá SPY với các điểm mua/bán của mô hình.
- Cho phép lựa chọn mô hình và giai đoạn backtest.



Hình 4.6: Biểu đồ chi tiết hiệu suất và rủi ro

- Biểu đồ thể hiện giá trị danh mục qua từng ngày (Portfolio Value).
- Các chỉ báo rủi ro như CVaR, Drawdown và Sortino ratio được cập nhật theo thời gian thực.
- Hỗ trợ so sánh trực quan giữa các chiến lược RL và Buy & Hold.

CHƯƠNG 5. KẾT LUẬN

5.1 Kết luận

Bài toán giao dịch định lượng đã triển khai thành công với các mô hình học tăng cường PPO, CVaR-PPO và Sortino-PPO.

Các mô hình RL học được chính sách giao dịch hiệu quả, vượt vốn ban đầu 10,000 USD, đồng thời kiểm soát rủi ro tốt hơn chiến lược Buy & Hold.

Buy & Hold mang lại lợi nhuận tuyệt đối cao nhất trong giai đoạn thị trường tăng mạnh, nhưng đi kèm biến động lớn, Max Drawdown và rủi ro đuôi cao hơn.

CVaR-PPO và Sortino-PPO hạn chế biến động xấu, kiểm soát rủi ro đuôi tốt hơn PPO, thể hiện hiệu quả của các chiến lược nhạy cảm rủi ro.

Hạn chế: các mô hình RL phụ thuộc dữ liệu huấn luyện, yêu cầu tối ưu nhiều tham số và chưa tối ưu hoàn toàn lợi nhuận tuyệt đối, do đó kết quả có thể thay đổi khi áp dụng trên thị trường hoặc tài sản khác.

Trade-off giữa lợi nhuận và rủi ro giải thích sự khác biệt kết quả giữa các phương pháp.

5.2 Hướng phát triển

Mở rộng đánh giá mô hình trên nhiều tài sản và thị trường khác nhau để kiểm chứng khả năng tổng quát hóa.

Kết hợp dữ liệu thị trường thực tế với dữ liệu giả lập để cải thiện robustness.

Thử nghiệm các reward function khác hoặc kết hợp thêm các yếu tố rủi ro (CVaR, Sortino, Max Drawdown) để tối ưu hóa trade-off lợi nhuận – rủi ro.

Triển khai mô hình trong web demo trực tiếp, kết hợp phân tích trực quan real-time hỗ trợ ra quyết định đầu tư.

TÀI LIỆU THAM KHẢO

- [1] Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017). Proximal Policy Optimization Algorithms. arXiv:1707.06347.
- [2] Rockafellar, R. T., & Uryasev, S. (2000). Optimization of Conditional Value-at-Risk. *Journal of Risk*, 2(3), 21–42.
- [3] Moody, J., & Saffell, M. (2001). Learning to Trade via Direct Reinforcement. *IEEE Transactions on Neural Networks*, 12(4), 875–889.
- [4] Tesauro, G. (1995). Temporal Difference Learning and TD-Gammon. *Communications of the ACM*, 38(3), 58–68.
- [5] Jiang, Z., Xu, D., & Liang, J. (2017). A Deep Reinforcement Learning Framework for the Financial Portfolio Management Problem. arXiv:1712.10018.
- [6] Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2nd ed.). MIT Press.
- [7] Théate, T., & Ernst, D. (2021). An application of deep reinforcement learning to algorithmic trading. *Expert Systems with Applications*, 173, 114632.
- [8] Jiang, Y., Olmo, J., & Atwi, M. (2024). Deep reinforcement learning for portfolio selection. *Global Finance Journal*.
- [9] Shavandi, A., & Khedmati, M. (2022). A multi-agent deep reinforcement learning framework for algorithmic trading in financial markets. *Expert Systems with Applications*, 200, 116959.
- [10] Kabbani, T., & Duman, E. (2022). Deep Reinforcement Learning Approach for Trading Automation in the Stock Market. *IEEE Access*, 10, 76612–76627.
- [11] Cui, T., Du, N., Yang, X., & Ding, S. (2024). Multi-period portfolio optimization using a deep reinforcement learning hyper-heuristic approach. *Technological Forecasting and Social Change*, 193, 122589.
- [12] Bühler, H., Gonon, L., Teichmann, J., & Wood, B. (2019). Deep hedging. *Quantitative Finance*, 19(8), 1271–1291.

- [13] Liu, X.-Y., Yang, H., Chen, Q., Zhang, R., Yang, L., Xiao, B., & Wang, C. (2020). FinRL: A Deep Reinforcement Learning Library for Automated Stock Trading in Quantitative Finance. arXiv preprint arXiv:2011.09607.
- [14] Lu, C. I. (2023). Evaluation of Deep Reinforcement Learning Algorithms for Portfolio Optimisation. arXiv preprint arXiv:2307.07407.
- [15] Aritonang, P. K., Wiryono, S. K., & Faturhman, T. (2024). Hidden-layer configurations in reinforcement learning models for stock portfolio optimization. *Intelligent Systems with Applications*, 20, 200347.
- [16] Sortino, F., & Price, L. (1994). Performance Measurement in a Downside Risk Framework. *Journal of Investing*, 3(3), 59–64.
- [17] Liang, Z., Chen, H., Zhu, J., Jiang, K., & Li, Y. (2018). Adversarial Deep Reinforcement Learning in Portfolio Management. arXiv: Portfolio Management.
- [18] Yang, H., Liu, X., Zhong, S., & Walid, A. (2020). Deep reinforcement learning for automated stock trading: an ensemble strategy. *Proceedings of the First ACM International Conference on AI in Finance*.
- [19] Cui, T., Ding, S., Jin, H., & Zhang, Y. (2022). Portfolio constructions in cryptocurrency market: A CVaR-based deep reinforcement learning approach. *Economic Modelling*. <https://doi.org/10.1016/j.econmod.2022.106078>.
- [20] Aboussalah, A., & Lee, C. (2020). Continuous control with Stacked Deep Dynamic Recurrent Reinforcement Learning for portfolio optimization. *Expert Systems with Applications*, 140. <https://doi.org/10.1016/j.eswa.2019.112891>.
- [21] Alameer, A., & Alshehri, K. (2021). Conditional Value-at-Risk for Quantitative Trading: A Direct Reinforcement Learning Approach. *2022 IEEE Conference on Control Technology and Applications (CCTA)*, 1208–1213. <https://doi.org/10.1109/ccta49430.2022.9966017>.
- [22] Jang, J., & Seong, N. (2023). Deep reinforcement learning for stock portfolio optimization by connecting with modern portfolio theory. *Expert Systems with Applications*, 218, 119556. <https://doi.org/10.1016/j.eswa.2023.119556>.
- [23] Wang, Z., Huang, B., Tu, S., Zhang, K., & Xu, L. (2021). DeepTrader: A Deep Reinforcement Learning Approach for Risk-Return Balanced Portfolio Management

with Market Conditions Embedding. AAAI 2021, 643–650. <https://doi.org/10.1609/aaai.v35i1.16144>.

[24] Zhang, Y., Zhao, P., Wu, Q., Li, B., Huang, J., & Tan, M. (2020). Cost-Sensitive Portfolio Selection via Deep Reinforcement Learning. *IEEE Transactions on Knowledge and Data Engineering*, 34, 236–248. <https://doi.org/10.1109/tkde.2020.2979700>.

[25] Niu, H., Li, S., & Li, J. (2022). MetaTrader: An Reinforcement Learning Approach Integrating Diverse Policies for Portfolio Optimization. *Proceedings of the 31st ACM International Conference on Information & Knowledge Management*. <https://doi.org/10.1145/3511808.3557363>.

[26] Almahdi, S., & Yang, S. (2017). An adaptive portfolio trading system: A risk-return portfolio optimization using recurrent reinforcement learning with expected maximum drawdown. *Expert Systems with Applications*, 87, 267–279. <https://doi.org/10.1016/j.eswa.2017.06.023>.

[27] Sun, Q., Wei, X., & Yang, X. (2023). GraphSAGE with deep reinforcement learning for financial portfolio optimization. *Expert Systems with Applications*, 238, 122027. <https://doi.org/10.1016/j.eswa.2023.122027>.

PHỤ LỤC

Phần này bao gồm những nội dung cần thiết nhằm minh họa hoặc hỗ trợ cho nội dung đề án như số liệu, biểu mẫu, tranh ảnh. . . . nếu sử dụng những câu trả lời cho một *bảng câu hỏi thì bảng câu hỏi mẫu này phải được đưa vào phần Phụ lục ở dạng nguyên bản* đã dùng để điều tra, thăm dò ý kiến; **không được tóm tắt hoặc sửa đổi**. Các tính toán mẫu trình bày tóm tắt trong các biểu mẫu cũng cần nêu trong Phụ lục của luận văn. Phụ lục không được dày hơn phần chính của đề án

LÀM VIỆC NHÓM

Đề tài: Risk-Sensitive Reinforcement Learning for Trading

Môn học: Giao dịch định lượng – GVHD: TS. Bùi Thanh Hùng

1. Thông tin nhóm

STT	Họ và tên	MSSV	Vai trò
1	Nguyễn Ngọc Lân	22635801	Thành viên
2	Lê Huỳnh Tấn Đạt	23634031	Thành viên

2. Phân công công việc chi tiết

STT	Công việc	Nguyễn Ngọc Lân	Lê Huỳnh Tấn Đạt
1	Thu thập dữ liệu thị trường (yfinance: SPY, QQQ, GLD)	✓	✓
2	Tiền xử lý dữ liệu: làm sạch, xử lý missing value, outlier	✓	✓
3	Tính toán chỉ báo kỹ thuật (SMA, RSI, MACD, BB, ATR)	✓	✓
4	Chuẩn hóa đặc trưng (Z-score), lưu norm_params.json	✓	
5	Xây dựng môi trường giao dịch (Trading Environment)	✓	✓
6	Xây dựng tín hiệu giao dịch (signals) và logic BUY/SELL/HOLD		✓
7	Xây dựng chỉ số đánh giá tài chính (Sharpe, Sortino, DD, CVaR...)		✓
8	Huấn luyện mô hình PPO (baseline, 300 episodes)	✓	

9	Huấn luyện mô hình CVaR-PPO (risk-sensitive)	✓	
10	Huấn luyện mô hình Sortino-PPO (downside risk)	✓	
11	Triển khai thử nghiệm và đánh giá mô hình	✓	✓
12	Phát triển ứng dụng Web Demo (Django)	✓	✓
13	Viết báo cáo đồ án và bài báo khoa học	✓	✓

3. Tóm tắt đóng góp từng thành viên

STT	Thành viên	Nội dung đóng góp chính	Tỷ lệ
1	Nguyễn Ngọc Lân	Chuẩn bị dữ liệu huấn luyện (thu thập, tiền xử lý, trích xuất đặc trưng, chuẩn hóa); Huấn luyện các mô hình RL (PPO, CVaR-PPO, Sortino-PPO – 300 episodes/CUDA); Hỗ trợ phát triển Web Demo (Django); Phối hợp viết báo cáo và paper.	50%
2	Lê Huỳnh Tấn Đạt	Xây dựng tín hiệu giao dịch (signals) và logic BUY/SELL/HOLD; Xây dựng chỉ số đánh giá tài chính (Total Return, Sharpe, Sortino, Max DD, CVaR-95, Win Rate); Triển khai thử nghiệm, kiểm tra dữ liệu; Hỗ trợ Demo và viết báo cáo.	50%

4. Lịch làm việc nhóm chi tiết

Thời gian thực hiện: Từ giữa tháng 3/2026 đến giữa tháng 5/2026 (khoảng 8 tuần).

Buổi	Thời gian	Hình thức	Nội dung công việc	Thời lượng
1	Tuần 1 (17–23/03)	Trực tiếp	Họp nhóm lần đầu: phân tích đề tài, phân công công việc, lên kế hoạch tổng thể	~3 giờ

2	Tuần 1 (17–23/03)	Trực tuyến	Nghiên cứu tài liệu liên quan: PPO, CVaR, Sortino Ratio, RL trong trading	~3 giờ
3	Tuần 2 (24–30/03)	Trực tiếp	Thu thập dữ liệu (yfinance), tiền xử lý OHLCV, thiết kế pipeline xử lý dữ liệu	~4 giờ
4	Tuần 2 (24–30/03)	Trực tuyến	Review code xử lý dữ liệu, tính toán chỉ báo kỹ thuật (SMA, RSI, MACD, BB, ATR)	~2 giờ
5	Tuần 3 (31/03–06/04)	Trực tiếp	Xây dựng môi trường RL (Trading Environment), thiết kế state vector 19 chiều	~4 giờ
6	Tuần 3 (31/03–06/04)	Trực tuyến	Xây dựng tín hiệu giao dịch (signals), logic BUY/SELL/HOLD, chuẩn hóa Z-score	~2 giờ
7	Tuần 4 (07–13/04)	Trực tiếp	Huấn luyện mô hình PPO (baseline), debug và kiểm tra kết quả huấn luyện ban đầu	~4 giờ
8	Tuần 4 (07–13/04)	Trực tuyến	Xây dựng các chỉ số đánh giá (Sharpe, Sortino, Max DD, CVaR-95, Win Rate)	~2 giờ
9	Tuần 5 (14–20/04)	Trực tiếp	Huấn luyện CVaR-PPO và Sortino-PPO, so sánh kết quả huấn luyện giữa 3 mô hình	~4 giờ
10	Tuần 5 (14–20/04)	Trực tuyến	Đánh giá trên tập test (SPY, QQQ, GLD), phân tích kết quả backtest	~3 giờ
11	Tuần 6 (21–27/04)	Trực tiếp	Phát triển Web Demo (Django): thiết kế giao diện, tích hợp mô hình	~4 giờ
12	Tuần 6 (21–27/04)	Trực tuyến	Kiểm thử Web Demo, sửa lỗi, tối ưu hiển thị biểu đồ và tín hiệu giao dịch	~2 giờ
13	Tuần 7 (28/04–04/05)	Trực tiếp	Hoàn thiện Demo, chạy backtest cuối cùng, tổng hợp kết quả thực nghiệm	~4 giờ
14	Tuần 7 (28/04–04/05)	Trực tuyến	Viết báo cáo: Chương 1-3, phân tích và trình bày phương pháp đề xuất	~3 giờ
15	Tuần 8 (05–11/05)	Trực tiếp	Review toàn bộ báo cáo, viết bài báo khoa học (paper), chỉnh sửa format	~4 giờ

16	Tuần 8 (05–11/05)	Trực tuyến	Hoàn thiện báo cáo Chương 4-5, kiểm tra lần cuối, chuẩn bị nộp bài	~3 giờ
----	----------------------	---------------	--	--------

Tổng số buổi làm việc: **16 buổi** (8 buổi trực tiếp + 8 buổi trực tuyến)

Tổng thời gian ước tính: **khoảng 51 giờ** (trực tiếp ~31 giờ, trực tuyến ~20 giờ).

Ngoài các buổi làm việc theo lịch trên, hai thành viên thường xuyên trao đổi qua Zalo và Google Meet để giải quyết vấn đề phát sinh, review code và cập nhật tiến độ công việc.

TỰ ĐÁNH GIÁ

Mục	Nội dung	Điểm chuẩn	Tự chấm	Ghi chú
1	Giới thiệu về bài toán	0.5	0.5	
2	Phân tích yêu cầu của bài toán	1	1	
3	Phương pháp giải quyết bài toán	2	2	
4	Thực nghiệm	3.5	3.5	
5	Kết luận	0.5	0.5	
6	Điểm bài báo	2.0	1.5	
7	Điểm nhóm	0.5	0.5	
Tổng điểm	9.5			